

Méthodes de Monte Carlo pour la modélisation géostatistique
non stationnaire sur données binaires

Table des matières

Liste des acronymes et principales notations	4
Introduction	6
Problématique	7
Objectifs du stage	8
Organisation du mémoire	9
1 Présentation d’INRAE et du cadre du stage	10
1.1 Présentation de l’INRAE	10
1.2 Le département Mathématiques et Numérique	10
1.3 L’unité Mathématiques et Informatique Appliquées de Toulouse (MIAT)	10
1.4 Positionnement du stage	11
2 Fondements théoriques	13
2.1 Processus gaussiens	13
2.1.1 Stationnarité	14
2.1.2 Isotropie	14
2.2 Fonction de covariance de Matérn	14
2.3 Extension des processus gaussiens à la non-stationnarité	15
2.4 Approximation de Vecchia	16
2.5 Inférence bayésienne	18
2.6 Positionnement du travail	18
3 Modèle géostatistique gaussien	20
3.1 Modèle géostatistique	20
3.2 Loi <i>a priori</i> et vraisemblance	21
3.3 Distribution <i>a posteriori</i>	21
3.4 Variance marginale et intervalles de crédibilité	22
3.5 Log-postérieure, gradient et courbure	23
3.6 Rôle du modèle gaussien dans l’étude	23
4 Méthodes de Monte Carlo par chaînes de Markov	25
4.1 Principe des méthodes MCMC	25
4.2 Algorithme de Metropolis–Hastings	26
4.3 Algorithme Metropolis–Adjusted Langevin (MALA)	26
4.4 Difficultés de MALA	27
4.5 Adaptation du pas de proposition	28
4.6 Préconditionnement	28
4.7 Variante à momentum inspirée des méthodes hamiltoniennes	30
4.7.1 Distribution augmentée	30
4.7.2 Rafraîchissement partiel du momentum	31
4.7.3 Étape de Leapfrog	31

4.7.4	Lien avec MALA préconditionné	31
4.7.5	Correction de Metropolis	32
4.8	Critères d'évaluation des chaînes	32
5	Expériences numériques sur le modèle gaussien	34
5.1	Protocole expérimental	34
5.2	Validation par la solution analytique	36
5.3	Résultats sur le champ latent et son incertitude	37
5.4	Précision de l'estimation de l'incertitude postérieure	39
5.5	Analyse de l'efficacité de l'échantillonnage	41
5.5.1	Performance et robustesse des stratégies	41
5.5.2	Influence des paramètres du modèle	42
6	Application au modèle géostatistique binaire	46
6.1	Modèle géostatistique binaire	46
6.1.1	Vraisemblance	47
6.1.2	Loi <i>a priori</i> du champ latent	47
6.1.3	Distribution <i>a posteriori</i>	47
6.1.4	Gradient et Hessienne de la log-postérieure	48
6.1.5	Du cas gaussien au cas binaire	48
6.1.6	Calcul du MAP (Maximum <i>A Posteriori</i>)	49
6.1.7	Stratégies de préconditionnement	49
6.2	Protocole expérimental	50
6.2.1	Génération des données	50
6.2.2	Initialisation et réglage des chaînes	50
6.2.3	Plan factoriel	51
6.2.4	Critères de comparaison	51
6.3	Reconstruction du champ latent et incertitude postérieure	52
6.4	Analyse de l'incertitude postérieure	54
6.5	Analyse de l'efficacité de l'échantillonnage	55
6.5.1	Comparaison globale des préconditionnements	55
6.5.2	Performance et robustesse des stratégies	56
6.5.3	Influence des paramètres du modèle	57
6.6	Discussion des résultats	60
7	Application au modèle géostatistique de Poisson	62
7.1	Modèle géostatistique de Poisson	62
7.1.1	Vraisemblance	63
7.1.2	Loi <i>a priori</i> du champ latent	63
7.1.3	Distribution <i>a posteriori</i>	63
7.1.4	Gradient et Hessienne de la log-postérieure	64
7.1.5	Du cas binaire au cas de Poisson	64
7.1.6	Calcul du MAP (Maximum <i>A Posteriori</i>)	65
7.1.7	Stratégies de préconditionnement	65
7.2	Protocole expérimental	66
7.2.1	Génération des données	66
7.2.2	Initialisation et réglage des chaînes	67
7.2.3	Plan factoriel	67
7.2.4	Critères de comparaison	68
7.3	Reconstruction du champ latent et incertitude postérieure	68
7.4	Analyse de l'incertitude postérieure	70
7.5	Analyse de l'efficacité de l'échantillonnage	71

7.5.1	Comparaison globale des préconditionnements	71
7.5.2	Performance et robustesse des stratégies	72
7.5.3	Influence des paramètres du modèle	73
7.6	Discussion des résultats	77
8	Conclusion générale, limites et perspectives	79
8.1	Principaux enseignements	79
8.2	Apport de l'analyse de l'incertitude postérieure	82
8.3	Limites de l'étude	82
8.4	Difficultés méthodologiques et numériques	83
8.5	Perspectives	84
A	Validations numériques complémentaires	87
A.1	Validations dans le modèle gaussien	87
A.2	Validations dans le modèle binaire	88
A.2.1	Validation numérique du gradient	88
A.2.2	Convergence du calcul du MAP	88
A.3	Validations dans le modèle de Poisson	89
A.3.1	Validation numérique du gradient	89
A.3.2	Convergence du calcul du MAP	90
A.3.3	Comparaison sur une configuration de référence	90

Glossaire

Acronymes

- INRAE** Institut national de recherche pour l’agriculture, l’alimentation et l’environnement.
- MIAT** Mathématiques et Informatique Appliquées de Toulouse.
- MathNum** Département Mathématiques et Numérique d’INRAE.
- MCMC** Monte Carlo par chaînes de Markov (*Markov Chain Monte Carlo*).
- MALA** Metropolis–Adjusted Langevin Algorithm.
- MAP** Maximum *a posteriori*, c’est-à-dire le mode de la distribution *a posteriori*.
- ESS** Taille effective d’échantillon (*Effective Sample Size*).
- NNGP** Processus gaussien fondé sur les plus proches voisins (*Nearest-Neighbor Gaussian Process*).
- RMSE** Racine de l’erreur quadratique moyenne (*Root Mean Squared Error*).

Principales notations

- n Nombre de sites spatiaux.
- s_i Position du i -ème site spatial.
- D Domaine spatial considéré.
- $y = (y_1, \dots, y_n)^\top$ Vecteur des observations.
- $w = (w_1, \dots, w_n)^\top$ Champ latent spatial évalué aux sites d’observation.
- X Matrice des covariables.
- β Vecteur des coefficients de régression.
- β_0 Intercept du modèle.
- β_1 Coefficient associé à la covariable.
- Σ Matrice de covariance du champ latent.
- Q_0 Matrice de précision *a priori* du champ latent.
- $\tilde{R}$ Facteur creux issu de l’approximation de Vecchia, tel que $Q_0 = \tilde{R}^\top \tilde{R}$.
- $N(i)$ Ensemble des voisins utilisés dans l’approximation de Vecchia pour le site i .
- σ^2 Variance du processus spatial.
- ν Paramètre de régularité de la covariance de Matérn.
- ℓ Paramètre de portée de la covariance spatiale.
- ℓ^* Portée effective utilisée dans les expériences.
- τ^2 Variance du bruit d’observation dans le modèle géostatistique gaussien.

Notations liées à la loi *a posteriori*

$\pi(w)$ Densité cible *a posteriori* du champ latent.

μ_{post} Moyenne *a posteriori* exacte dans le modèle gaussien.

Q_{post} Matrice de précision *a posteriori* exacte dans le modèle gaussien.

w_{MAP} Valeur du champ latent maximisant la densité *a posteriori*.

Q_{MAP} Matrice construite à partir de la courbure locale de la log-postérieure au MAP dans les modèles non gaussiens.

$\nabla \log \pi(w)$ Gradient de la log-densité *a posteriori*.

$\nabla^2 \log \pi(w)$ Hessienne de la log-densité *a posteriori*.

Notations liées à l’algorithme MALA

s Pas de proposition de l’algorithme MALA.

w^* Valeur proposée du champ latent lors d’une itération MCMC.

p Variable auxiliaire de momentum.

ρ Paramètre contrôlant la persistance du momentum.

M Matrice utilisée pour préconditionner les déplacements de l’algorithme.

α Probabilité d’acceptation de la proposition Metropolis–Hastings.

Notations spécifiques aux modèles non gaussiens

η_i Prédicteur linéaire au site i , généralement défini par $\eta_i = x_i^\top \beta + w_i$.

p_i Probabilité de succès au site i dans le modèle géostatistique binaire.

λ_i Intensité conditionnelle au site i dans le modèle géostatistique de Poisson.

$D(w)$ Matrice diagonale représentant la contribution locale de la vraisemblance à la courbure dans le modèle binaire.

$D_\lambda(w)$ Matrice diagonale représentant la contribution locale de la vraisemblance à la courbure dans le modèle de Poisson.

Indicateurs numériques

Q_{10} Premier décile de la distribution de l’ESS médian sur les différentes configurations. Il correspond à la valeur en dessous de laquelle se situent 10 % des ESS médians observés.

Introduction

Les données spatiales occupent aujourd’hui une place importante dans de nombreux domaines scientifiques tels que l’environnement, l’agronomie, l’écologie, la climatologie ou encore la santé publique. Elles sont caractérisées par une dépendance entre les observations, les mesures réalisées en des lieux proches étant généralement plus similaires que celles effectuées en des lieux éloignés. La prise en compte de cette dépendance est indispensable pour produire des estimations fiables et améliorer les capacités de prédiction des modèles statistiques.

Les processus gaussiens constituent un cadre de modélisation particulièrement adapté à ce type de données. Ils permettent de représenter la structure de dépendance spatiale à l’aide d’une fonction de covariance tout en offrant un cadre probabiliste rigoureux pour l’inférence et la prédiction. Cependant, leur utilisation devient rapidement coûteuse lorsque le nombre d’observations augmente, notamment en raison des opérations de factorisation et de résolution de systèmes linéaires impliquant de grandes matrices de covariance.

Pour répondre à cette difficulté, plusieurs approches ont été développées afin de réduire le coût des calculs. Parmi elles, l’approximation de Vecchia permet d’exploiter une représentation creuse de la dépendance spatiale en conditionnant chaque observation sur un nombre limité de voisins. Cette structure est particulièrement intéressante pour les calculs numériques en grande dimension.

Dans un cadre bayésien, l’objectif est d’inférer la distribution *a posteriori* des variables latentes à partir des observations. Lorsque cette distribution ne possède pas d’expression analytique simple, les méthodes de Monte Carlo par chaînes de Markov (MCMC) constituent une approche de référence pour générer des échantillons selon cette loi. Dans les modèles géostatistiques considérés ici, la dépendance spatiale induit des dépendances entre les composantes du champ latent. En grande dimension, cette structure peut ralentir l’exploration de la distribution *a posteriori* et conduire à une forte autocorrélation des échantillons MCMC. L’enjeu n’est donc pas seulement de construire une chaîne ayant la bonne distribution cible, mais également d’obtenir des échantillons suffisamment peu autocorrélés pour permettre une inférence efficace.

Ce mémoire s’inscrit dans le cadre d’un stage réalisé au sein de l’unité Mathématiques et Informatique Appliquées de Toulouse (MIAT) de l’INRAE. Les travaux portent sur l’amélioration de l’efficacité de l’échantillonnage MCMC des champs latents dans des modèles géostatistiques. L’étude est menée dans un premier temps sur un modèle gaussien, pour lequel la loi *a posteriori* est connue analytiquement et peut servir de référence pour valider les méthodes numériques. Elle est ensuite étendue à deux modèles non gaussiens : un modèle géostatistique binaire et un modèle géostatistique de Poisson pour des données de comptage. Dans ces deux cas, la loi *a posteriori* du champ latent ne possède plus de forme analytique explicite, ce qui nécessite le recours aux méthodes MCMC.

Les expériences sont réalisées sur des données simulées, ce qui permet de contrôler les paramètres du modèle et de disposer du champ latent ayant généré les observations. La dimension du champ constitue une contrainte numérique importante. L’approximation de Vecchia et l’utilisation de matrices creuses permettent de limiter le coût des opérations matricielles nécessaires à l’inférence.

Problématique

Les modèles géostatistiques bayésiens reposent sur l'inférence d'un champ latent décrivant la structure spatiale du phénomène étudié. Dans le cas gaussien, la loi *a posteriori* du champ latent possède une expression analytique. En revanche, pour des modèles non gaussiens, notamment lorsque les observations sont binaires, cette loi n'est plus disponible sous forme fermée et doit être explorée numériquement.

Les méthodes de Monte Carlo par chaînes de Markov constituent une approche de référence pour échantillonner ces distributions *a posteriori*. Parmi elles, le Metropolis–Adjusted Langevin Algorithm (MALA) exploite le gradient de la log-densité cible afin d'orienter les propositions vers les régions de forte probabilité.

Dans les problèmes géostatistiques considérés ici, la grande dimension du champ latent et les dépendances spatiales peuvent toutefois conduire à une forte autocorrélation des échantillons et donc à une faible efficacité de l'algorithme. Les performances de MALA dépendent notamment du pas de proposition, du préconditionnement et de la persistance du momentum.

La problématique centrale du stage peut ainsi être résumée par la question suivante :

Comment construire une stratégie MALA à la fois performante et robuste pour l'échantillonnage d'un champ latent dans des modèles géostatistiques de grande dimension ?

Par *performante*, on entend une stratégie permettant de produire des échantillons faiblement autocorrélés et donc une taille effective d'échantillon élevée. Par *robuste*, on entend une stratégie conservant de bonnes performances lorsque les paramètres du modèle et, par conséquent, la géométrie de la distribution *a posteriori* varient.

Pour répondre à cette question, trois composantes de la stratégie MALA sont étudiées : l'adaptation du pas de proposition, le préconditionnement et la persistance du momentum. Le modèle gaussien, pour lequel la loi *a posteriori* est connue analytiquement, est d'abord utilisé comme cadre de validation et de comparaison. L'étude est ensuite étendue à deux modèles non gaussiens, un modèle binaire et un modèle de Poisson, pour lesquels la géométrie de la loi *a posteriori* est caractérisée localement à partir du MAP et de la Hessienne.

Illustration du problème d'inférence

Le phénomène étudié est supposé être gouverné par un champ latent spatial, qui représente la structure de dépendance sous-jacente des données. À partir de ce champ latent, il est possible de générer des observations selon le mécanisme d'observation propre au modèle considéré. Cette étape correspond au **problème direct**.

À l'inverse, dans une situation d'inférence, seules les observations sont disponibles. L'objectif est alors de caractériser et d'échantillonner la distribution du champ latent conditionnellement à ces observations. Cette étape constitue le **problème inverse** étudié dans ce mémoire.




FIGURE 1 – Illustration du problème direct : les observations sont générées à partir d'un champ latent spatial.




FIGURE 2 – Illustration du problème inverse : le champ latent est inféré à partir des observations.

Objectifs du stage

Afin de répondre à cette problématique, le travail réalisé au cours du stage s'articule autour des objectifs suivants :

- utiliser le modèle géostatistique gaussien comme cadre de validation, grâce à l'existence d'une loi *a posteriori* analytique ;
- implémenter et comparer différentes stratégies MALA combinant adaptation du pas, pré-conditionnement et persistance du momentum ;
- évaluer leur performance et leur robustesse lorsque les paramètres du modèle varient ;
- étendre la démarche aux modèles géostatistiques non gaussiens, d'abord au modèle binaire puis au modèle de Poisson, pour lesquels la géométrie de la loi *a posteriori* est caractérisée localement à partir du MAP et de la Hessienne ;
- étudier si les conclusions obtenues sur le choix du préconditionnement et de la persistance du momentum restent valables lorsque le mécanisme d'observation change ;
- identifier une stratégie MALA offrant un bon compromis entre efficacité d'échantillonnage, robustesse, qualité de l'inférence et coût de calcul.

Organisation du mémoire

Le mémoire est organisé en huit chapitres.

Le premier chapitre présente l'INRAE, le département Mathématiques et Numérique, l'unité MIAT ainsi que le contexte scientifique et les missions du stage.

Le deuxième chapitre présente les fondements théoriques nécessaires à l'étude ainsi que les principaux travaux sur lesquels elle s'appuie. Il introduit notamment les processus gaussiens, la covariance de Matérn, l'approximation de Vecchia et le cadre bayésien, avant de situer le travail réalisé par rapport aux approches existantes.

Le troisième chapitre décrit le modèle géostatistique gaussien utilisé comme cadre de référence et établit analytiquement la distribution *a posteriori* du champ latent.

Le quatrième chapitre présente les méthodes MCMC considérées dans ce travail, en particulier MALA, l'adaptation du pas de proposition, le préconditionnement et la variante introduisant une persistance du momentum.

Le cinquième chapitre présente les expériences numériques réalisées sur le modèle gaussien. La solution analytique permet d'abord de valider l'implémentation et d'évaluer la précision des estimations de la moyenne et de la variance *a posteriori*. La performance et la robustesse des différentes stratégies MALA sont ensuite étudiées lorsque les paramètres du modèle varient.

Le sixième chapitre étend l'étude au modèle géostatistique binaire. L'absence de forme analytique de la loi *a posteriori* conduit à caractériser localement sa géométrie à partir du MAP et de la Hessienne. Les différentes stratégies MALA sont ensuite comparées en termes d'efficacité, de robustesse et de reconstruction du champ latent, complétée par une analyse de l'incertitude *a posteriori*.

Le septième chapitre étend la démarche à un modèle géostatistique de Poisson pour des données de comptage. La géométrie locale de la loi *a posteriori* est de nouveau exploitée à travers la courbure au MAP afin de construire un préconditionnement adapté. Les performances des différentes stratégies MALA sont étudiées sur un plan factoriel et comparées à celles obtenues dans le modèle binaire. La reconstruction du champ latent et son incertitude *a posteriori* sont également analysées.

Enfin, **le huitième chapitre** propose une synthèse générale des travaux réalisés et des principaux résultats obtenus. Il présente également les limites de l'étude, les principales difficultés méthodologiques et numériques rencontrées au cours du stage, ainsi que les perspectives de prolongement de ce travail.

Chapitre 1

Présentation d'INRAE et du cadre du stage

Ce chapitre présente l'organisme d'accueil et le cadre scientifique dans lequel s'inscrit le stage. Après une brève présentation de l'INRAE, du département Mathématiques et Numérique et de l'unité Mathématiques et Informatique Appliquées de Toulouse (MIAT), le positionnement méthodologique du travail réalisé est précisé.

1.1 Présentation de l'INRAE

L'Institut national de recherche pour l'agriculture, l'alimentation et l'environnement (INRAE) est un établissement public français de recherche créé le 1^{er} janvier 2020 à la suite de la fusion de l'INRA et d'Irstea. Il est placé sous la tutelle du ministère chargé de la Recherche et du ministère chargé de l'Agriculture.

INRAE conduit des recherches dans les domaines de l'agriculture, de l'alimentation et de l'environnement afin de répondre à différents enjeux scientifiques et sociétaux, notamment la transition agroécologique, le changement climatique, la gestion durable des ressources naturelles et la sécurité alimentaire.

L'institut est organisé en plusieurs départements scientifiques couvrant des disciplines variées. Parmi eux, le département Mathématiques et Numérique rassemble des travaux en mathématiques appliquées, statistique, informatique, modélisation et sciences des données.

1.2 Le département Mathématiques et Numérique

Le stage a été réalisé au sein du département **Mathématiques et Numérique** (MathNum) d'INRAE.

Ce département développe des méthodes mathématiques, statistiques, numériques et informatiques destinées à l'analyse de systèmes complexes et de données de grande dimension. Ces travaux sont menés en interaction avec les problématiques scientifiques rencontrées dans les domaines de l'agriculture, de l'environnement et des sciences du vivant.

Le stage s'inscrit plus particulièrement dans cette composante méthodologique, à travers l'étude de méthodes numériques pour l'inférence statistique bayésienne.

1.3 L'unité Mathématiques et Informatique Appliquées de Toulouse (MIAT)

Le stage s'est déroulé au sein de l'unité **Mathématiques et Informatique Appliquées de Toulouse** (MIAT).

Cette unité développe des recherches en statistique, probabilités, recherche opérationnelle, optimisation, intelligence artificielle et apprentissage statistique. Les méthodes développées sont notamment appliquées aux domaines de l'agriculture, de l'environnement et des sciences du vivant.

Les travaux menés à MIAT portent en particulier sur la modélisation probabiliste, l'inférence statistique et le développement de méthodes numériques adaptées à l'analyse de données complexes et de grande dimension.

Le stage s'inscrit dans cette thématique à travers l'étude de méthodes d'échantillonnage par Monte Carlo par chaînes de Markov (MCMC) pour l'inférence de champs latents dans des modèles géostatistiques bayésiens.



FIGURE 1.1 – Équipe de l'unité Mathématiques et Informatique Appliquées de Toulouse (MIAT).

1.4 Positionnement du stage

Le travail réalisé porte sur une problématique méthodologique liée à l'échantillonnage de champs latents de grande dimension dans des modèles géostatistiques bayésiens.

L'étude se concentre sur l'algorithme *Metropolis-Adjusted Langevin Algorithm* (MALA), qui exploite le gradient de la log-densité cible afin de guider les propositions de la chaîne de Markov.

Plusieurs mécanismes susceptibles d'améliorer son efficacité sont étudiés : l'adaptation automatique du pas de proposition, le préconditionnement et la persistance du momentum. L'objectif est d'identifier une stratégie permettant d'obtenir des échantillons peu autocorrélés tout en conservant de bonnes performances lorsque les caractéristiques du modèle varient.

La démarche est organisée progressivement. Un modèle géostatistique gaussien est d'abord utilisé comme cadre de validation, puisque sa loi *a posteriori* peut être calculée analytiquement. L'étude est ensuite étendue à deux modèles non gaussiens : un modèle pour données binaires et un modèle de Poisson pour données de comptage.

Ces extensions permettent d'étudier le comportement des stratégies MALA lorsque la géométrie de la distribution *a posteriori* n'est plus connue explicitement et doit être approchée localement, notamment à partir du MAP et de la Hessienne.

La problématique générale, les objectifs et la démarche scientifique du stage sont présentés dans l'introduction générale.

Conclusion

Ce chapitre a permis de situer le stage dans son environnement institutionnel et scientifique. Les travaux réalisés s'inscrivent dans les activités méthodologiques de l'unité MIAT autour de la modélisation probabiliste, de l'inférence statistique et du calcul en grande dimension.

Le chapitre suivant présente les fondements théoriques et les principaux travaux de la littérature nécessaires à la formulation des modèles géostatistiques et au développement des méthodes d'inférence étudiées dans ce mémoire.

Chapitre 2

Fondements théoriques

Ce chapitre présente les principaux fondements théoriques nécessaires à la compréhension des modèles et des méthodes d'inférence étudiés dans ce mémoire. Les processus gaussiens et la covariance de Matérn sont d'abord introduits afin de définir le cadre de modélisation spatiale. Le contexte scientifique du stage est ensuite présenté à travers les modèles géostatistiques non stationnaires et leur extension aux données non gaussiennes.

L'approximation de Vecchia, utilisée pour réduire le coût des calculs en grande dimension, est ensuite décrite. Enfin, le cadre de l'inférence bayésienne est rappelé et le positionnement du travail réalisé au cours du stage par rapport aux approches existantes est précisé.

2.1 Processus gaussiens

Les processus gaussiens constituent un outil fondamental pour la modélisation des phénomènes spatiaux. Ils permettent de représenter la dépendance entre des variables observées ou latentes associées à différentes positions d'un domaine spatial.

Définition 2.1. *Un processus gaussien est une famille de variables aléatoires*

$$\{W(s), s \in D\},$$

où $D \subset \mathbb{R}^d$ désigne le domaine spatial, telle que, pour tout ensemble fini de positions $s_1, \dots, s_n$, le vecteur

$$w = (W(s_1), \dots, W(s_n))^T$$

suit une loi normale multivariée

$$w \sim \mathcal{N}(\mu, \Sigma),$$

avec

$$\mu = (m(s_1), \dots, m(s_n))^T, \quad \Sigma_{ij} = C(s_i, s_j),$$

où $m(\cdot)$ désigne la fonction de moyenne et $C(\cdot, \cdot)$ la fonction de covariance du processus.

Un processus gaussien est donc entièrement caractérisé par sa fonction de moyenne et sa fonction de covariance. Dans les modèles étudiés dans ce mémoire, la composante spatiale est représentée par un champ latent gaussien. La fonction de covariance joue alors un rôle central puisqu'elle détermine la structure de dépendance entre les différentes composantes du champ.




FIGURE 2.1 – Exemple de réalisation d'un processus gaussien spatial.

2.1.1 Stationnarité

Un processus gaussien est dit stationnaire au second ordre lorsque sa moyenne est constante,

$$m(s) = \mu,$$

et lorsque sa covariance entre deux positions dépend uniquement du vecteur qui les sépare :

$$C(s_i, s_j) = C(s_i - s_j).$$

La structure de dépendance spatiale est alors supposée identique quelle que soit la position considérée dans le domaine.

2.1.2 Isotropie

Un processus stationnaire est dit isotrope lorsque sa covariance dépend uniquement de la distance euclidienne

$$h = \|s_i - s_j\|$$

entre deux positions. La covariance peut alors s'écrire

$$C(s_i, s_j) = C(h).$$

L'isotropie signifie ainsi que la dépendance spatiale ne dépend pas de la direction séparant les deux positions, mais uniquement de leur distance.

Ces hypothèses permettent de construire des modèles spatiaux relativement simples tout en conservant une grande variété de structures de dépendance. Parmi les fonctions de covariance utilisées dans ce cadre, la famille de Matérn occupe une place importante en géostatistique.

2.2 Fonction de covariance de Matérn

La fonction de covariance décrit la manière dont la dépendance spatiale évolue avec la distance entre deux positions. La famille de Matérn est particulièrement utilisée en géostatistique en raison de sa flexibilité : elle permet notamment de contrôler la variance du processus, l'échelle de dépendance spatiale et la régularité des réalisations.

Pour deux positions s_i et s_j , séparées par une distance

$$h = \|s_i - s_j\|,$$

une paramétrisation courante de la covariance de Matérn est

$$C(h) = \sigma^2 \frac{2^{1-\nu}}{\Gamma(\nu)} \left(\frac{\sqrt{2\nu} h}{\ell} \right)^\nu K_\nu \left(\frac{\sqrt{2\nu} h}{\ell} \right), \quad (2.1)$$

où

- $\sigma^2 > 0$ est la variance marginale du processus ;
- $\ell > 0$ est un paramètre d'échelle contrôlant la décroissance de la dépendance spatiale ;
- $\nu > 0$ est le paramètre de régularité ;
- K_ν désigne la fonction de Bessel modifiée de seconde espèce ;
- $\Gamma(\cdot)$ est la fonction Gamma.

Influence des paramètres

La variance σ^2 contrôle l'amplitude des variations du processus. Une augmentation de ce paramètre accroît la variabilité marginale du champ sans modifier, à paramètres ℓ et ν fixés, la structure de corrélation.

Le paramètre ℓ contrôle l'échelle de la dépendance spatiale. Une valeur élevée entraîne une décroissance plus lente de la corrélation avec la distance, tandis qu'une faible valeur conduit à une dépendance plus locale.

Le paramètre de régularité ν contrôle la régularité des réalisations. Lorsque ν augmente, les trajectoires du processus deviennent plus régulières. À l'inverse, de faibles valeurs de ν produisent des champs présentant davantage de fluctuations locales.




FIGURE 2.2 – Influence des paramètres de la covariance de Matérn sur la structure spatiale du processus.

La covariance de Matérn constitue ainsi un modèle de référence pour décrire la dépendance du champ latent. Les expériences numériques de ce mémoire reposent principalement sur cette structure spatiale.

2.3 Extension des processus gaussiens à la non-stationnarité

Les hypothèses de stationnarité et d'isotropie sont utiles pour construire des modèles spatiaux parcimonieux, mais elles peuvent être trop restrictives dans certaines applications. La variabilité du phénomène étudié, son échelle de dépendance ou encore la variance du bruit d'observation peuvent évoluer selon la position dans le domaine.

Les modèles géostatistiques non stationnaires permettent de représenter de telles situations en autorisant certains paramètres du modèle spatial à varier dans l'espace. La covariance entre deux positions ne dépend alors plus uniquement de leur distance ou de leur différence.

Dans les travaux de [Coube-Sisqueille, 2021], Coube, Banerjee et Liquet développent un modèle géostatistique bayésien hiérarchique permettant de prendre en compte différentes formes de non-stationnarité. L'inférence repose sur une stratégie MCMC organisée autour d'un schéma de type Gibbs, combinée à des mécanismes destinés à améliorer l'efficacité de l'échantillonnage. Le champ gaussien latent constitue notamment l'une des composantes devant être simulées au cours de l'algorithme.

Les expériences numériques et applications présentées dans ces travaux montrent l'intérêt de prendre en compte une structure de covariance non stationnaire lorsque les caractéristiques spatiales du phénomène varient dans le domaine. La prise en compte d'une éventuelle hétéroscédasticité du bruit d'observation peut également améliorer la qualité de la modélisation lorsque la variabilité résiduelle n'est pas homogène.

Ces travaux constituent une partie du contexte scientifique dans lequel s'inscrit le stage. Une implémentation de ces modèles est notamment développée au sein de MIAT à travers le package R `GeoNonStat`.

Une difficulté supplémentaire apparaît lorsque les observations ne sont plus gaussiennes. Dans un modèle hiérarchique, le champ latent peut conserver une loi *a priori* gaussienne alors que la loi conditionnelle des observations devient, par exemple, Bernoulli ou Poisson. Dans ce cas, la distribution conditionnelle *a posteriori* du champ latent n'est généralement plus gaussienne et ne peut plus être simulée directement.

Cette difficulté motive l'étude de méthodes MCMC adaptées à l'échantillonnage du champ latent, qui constitue le cœur du travail réalisé dans ce mémoire.

2.4 Approximation de Vecchia

L'un des principaux défis des modèles géostatistiques est le coût de calcul associé à la manipulation des matrices de covariance. Pour un processus gaussien évalué en n positions, une factorisation dense de la matrice de covariance présente généralement un coût de l'ordre de $O(n^3)$ et un stockage de l'ordre de $O(n^2)$. Ces coûts deviennent rapidement contraignants lorsque n augmente.

L'approximation proposée par Vecchia [Coube-Sisqueille, 2021] repose sur une factorisation conditionnelle de la densité jointe. Pour un vecteur gaussien

$$w = (w_1, \dots, w_n)^\top,$$

la densité jointe peut être écrite exactement sous la forme

$$p(w) = \prod_{i=1}^n p(w_i \mid w_1, \dots, w_{i-1}). \quad (2.2)$$

L'idée de l'approximation de Vecchia consiste à remplacer, pour chaque composante, l'ensemble des composantes précédentes par un sous-ensemble $N(i)$ de taille limitée :

$$p(w) \approx \prod_{i=1}^n p(w_i \mid w_{N(i)}), \quad (2.3)$$

avec

$$N(i) \subset \{1, \dots, i-1\}.$$

Les ensembles $N(i)$ sont généralement construits à partir de voisins spatiaux proches parmi les positions précédemment ordonnées. Lorsque leur taille reste faible devant n , cette approximation réduit fortement le nombre de dépendances à prendre en compte.




FIGURE 2.3 – Principe de l’approximation de Vecchia : chaque composante est conditionnée uniquement par un nombre limité de voisins précédemment ordonnés.

Dans l’implémentation utilisée dans ce mémoire, l’approximation conduit à une représentation creuse de la précision du champ latent. Celle-ci peut être écrite sous la forme

$$Q_0 = \tilde{R}^\top \tilde{R}, \quad (2.4)$$

où $\tilde{R}$ est une matrice triangulaire creuse issue de l’approximation de Vecchia.

Le champ latent est alors représenté approximativement par

$$w \sim \mathcal{N}(0, Q_0^{-1}). \quad (2.5)$$

Cette formulation est particulièrement utile pour les calculs réalisés dans la suite du mémoire. En effet,

$$Q_0 w = \tilde{R}^\top (\tilde{R} w),$$

ce qui permet d’exploiter directement la structure creuse de $\tilde{R}$, sans construire ni inverser une matrice de covariance dense.

Cette représentation intervient dans la simulation du champ latent, le calcul de la log-densité *a priori*, le calcul de son gradient ainsi que dans la construction des matrices de préconditionnement étudiées par la suite.

L'approximation de Vecchia constitue ainsi un élément essentiel de l'implémentation numérique : elle permet de conserver une représentation spatiale exploitable lorsque la dimension du champ latent augmente.

2.5 Inférence bayésienne

L'inférence bayésienne fournit un cadre probabiliste permettant de combiner l'information disponible avant l'observation des données avec celle apportée par les observations.

Pour un vecteur de paramètres ou de variables latentes θ et un vecteur d'observations y , le théorème de Bayes s'écrit

$$p(\theta | y) = \frac{p(y | \theta)p(\theta)}{p(y)}, \quad (2.6)$$

où

$$p(y) = \int p(y | \theta)p(\theta) d\theta \quad (2.7)$$

est la vraisemblance marginale des observations.

La distribution $p(\theta)$ représente la loi *a priori*, $p(y | \theta)$ la vraisemblance et $p(\theta | y)$ la distribution *a posteriori*.

Lorsque l'objectif porte uniquement sur la distribution de θ , le terme $p(y)$ ne dépend pas de θ . On peut donc écrire

$$p(\theta | y) \propto p(y | \theta)p(\theta). \quad (2.8)$$

Dans ce mémoire, les paramètres de covariance et les coefficients de régression sont considérés comme fixés dans les expériences numériques. La quantité d'intérêt principale est le champ latent w . L'inférence consiste donc à caractériser ou à échantillonner

$$p(w | y).$$

La difficulté dépend directement du modèle d'observation considéré.

Dans le modèle gaussien, la conjugaison permet d'obtenir explicitement une loi *a posteriori* gaussienne pour w . Cette propriété fournit une solution analytique de référence permettant de valider les estimations obtenues par MCMC.

Dans les modèles binaire et de Poisson, la vraisemblance n'est plus gaussienne. La distribution *a posteriori* du champ latent ne possède alors plus la même forme analytique explicite. Son exploration nécessite des méthodes numériques telles que les méthodes de Monte Carlo par chaînes de Markov étudiées dans ce mémoire.

2.6 Positionnement du travail

Les éléments présentés dans ce chapitre définissent le cadre scientifique et numérique du mémoire. Les processus gaussiens et la covariance de Matérn fournissent le modèle spatial du champ latent, tandis que l'approximation de Vecchia permet d'obtenir une représentation creuse de sa précision adaptée aux calculs de grande dimension. Les modèles géostatistiques non stationnaires constituent quant à eux une partie du contexte scientifique ayant motivé l'étude de méthodes d'inférence pouvant être étendues à des observations non gaussiennes.

Le travail réalisé au cours du stage ne vise pas à proposer une nouvelle fonction de covariance ni une nouvelle approximation de Vecchia. Il se concentre sur une étape particulière de l'inférence : l'échantillonnage efficace du champ latent.

L'étude porte plus précisément sur une stratégie fondée sur MALA et sur plusieurs mécanismes susceptibles d'améliorer son efficacité : l'adaptation du pas de proposition, le préconditionnement et la persistance du momentum.

La démarche suivie est progressive. Le modèle gaussien est d'abord utilisé comme cadre de validation, puisque sa distribution *a posteriori* est connue analytiquement. L'étude est ensuite étendue au modèle binaire puis au modèle de Poisson, pour lesquels cette distribution n'est plus disponible sous une forme analytique directement exploitable.

Dans les modèles non gaussiens, une approximation locale de la géométrie de la distribution cible est construite à partir du maximum *a posteriori* (MAP) et de la Hessienne. Elle permet notamment de définir un préconditionnement adapté à la courbure locale de la distribution.

Les méthodes d'échantillonnage et les différentes stratégies de préconditionnement sont présentées au chapitre 4.

Conclusion

Ce chapitre a présenté les principaux fondements nécessaires à la compréhension des modèles étudiés dans ce mémoire. Les processus gaussiens et la covariance de Matérn définissent la structure spatiale du champ latent. L'approximation de Vecchia fournit une représentation creuse de sa précision, adaptée aux calculs de grande dimension, tandis que le cadre bayésien permet de formuler l'inférence du champ latent conditionnellement aux observations.

Le contexte des modèles géostatistiques non stationnaires met également en évidence l'intérêt de disposer de méthodes d'échantillonnage pouvant être utilisées lorsque le modèle d'observation devient non gaussien.

Le chapitre suivant présente le modèle géostatistique gaussien. Dans ce cas, la distribution *a posteriori* du champ latent est disponible analytiquement, ce qui permettra de disposer d'une référence pour valider les méthodes MCMC étudiées par la suite.

Chapitre 3

Modèle géostatistique gaussien

Ce chapitre présente le modèle géostatistique gaussien utilisé comme cadre de référence pour l'évaluation des méthodes MCMC étudiées dans ce mémoire. Son intérêt principal réside dans le fait que la distribution *a posteriori* du champ latent possède une expression analytique. Les estimations obtenues par MCMC peuvent ainsi être comparées à des quantités de référence exactes.

Dans toute la suite, les coefficients de régression β , la variance du bruit d'observation τ^2 et les paramètres de covariance du champ latent sont considérés comme fixés. L'inférence porte uniquement sur le champ latent w .

Après la définition du modèle, la loi *a priori*, la vraisemblance et la distribution *a posteriori* du champ latent sont établies. La moyenne et la covariance *a posteriori* obtenues analytiquement serviront de référence pour évaluer à la fois la reconstruction du champ latent et l'incertitude estimée par MCMC dans le chapitre 5.

3.1 Modèle géostatistique

On considère un phénomène spatial observé en n positions

$$s_1, \dots, s_n \in D, \quad D \subset \mathbb{R}^2.$$

Le vecteur des observations est noté

$$y = (y_1, \dots, y_n)^\top.$$

La dépendance spatiale est représentée par un champ latent gaussien

$$w = (w_1, \dots, w_n)^\top, \quad w_i = W(s_i).$$

Dans l'approximation de Vecchia présentée au chapitre 2, la précision *a priori* du champ latent est représentée par la matrice creuse

$$Q_0 = \tilde{R}^\top \tilde{R}. \quad (3.1)$$

On suppose ainsi

$$w \sim \mathcal{N}(0, Q_0^{-1}). \quad (3.2)$$

Les observations sont obtenues en combinant un effet fixe, le champ latent et un bruit gaussien indépendant :

$$y = X\beta + w + \varepsilon, \quad (3.3)$$

avec

$$\varepsilon \sim \mathcal{N}(0, \tau^2 I_n), \quad (3.4)$$

indépendamment de w .

Conditionnellement au champ latent,

$$y \mid w, \beta \sim \mathcal{N}(X\beta + w, \tau^2 I_n). \quad (3.5)$$

Cette formulation sépare trois composantes : l'effet déterministe $X\beta$, la structure spatiale portée par w et la variabilité résiduelle représentée par ε .

3.2 Loi *a priori* et vraisemblance

D'après (3.2), la densité *a priori* du champ latent est

$$p(w) = (2\pi)^{-n/2} |Q_0|^{1/2} \exp\left(-\frac{1}{2} w^\top Q_0 w\right). \quad (3.6)$$

Cette distribution décrit la structure spatiale du champ avant la prise en compte des observations.

D'après (3.5), la vraisemblance s'écrit

$$p(y \mid w, \beta) = (2\pi\tau^2)^{-n/2} \exp\left[-\frac{1}{2\tau^2} (y - X\beta - w)^\top (y - X\beta - w)\right]. \quad (3.7)$$

Elle mesure la compatibilité entre les observations et les différentes valeurs possibles du champ latent.

3.3 Distribution *a posteriori*

L'objectif de l'inférence est de caractériser la distribution du champ latent conditionnellement aux observations. D'après le théorème de Bayes,

$$p(w \mid y, \beta) = \frac{p(y \mid w, \beta)p(w)}{p(y \mid \beta)}. \quad (3.8)$$

Le terme $p(y \mid \beta)$ ne dépend pas de w ,

$$p(w \mid y, \beta) \propto p(y \mid w, \beta)p(w). \quad (3.9)$$

En combinant la vraisemblance gaussienne et la loi *a priori*, la log-densité *a posteriori* s'écrit, à une constante additive près,

$$\log p(w \mid y, \beta) = -\frac{1}{2} w^\top Q_0 w - \frac{1}{2\tau^2} (y - X\beta - w)^\top (y - X\beta - w) + C. \quad (3.10)$$

En développant le terme quadratique,

$$\begin{aligned} (y - X\beta - w)^\top (y - X\beta - w) &= (y - X\beta)^\top (y - X\beta) \\ &\quad - 2w^\top (y - X\beta) + w^\top w. \end{aligned} \quad (3.11)$$

Le premier terme ne dépend pas de w et peut être absorbé dans la constante. On obtient donc

$$\log p(w \mid y, \beta) = -\frac{1}{2} w^\top (Q_0 + \tau^{-2} I_n) w + \tau^{-2} w^\top (y - X\beta) + C. \quad (3.12)$$

On reconnaît la forme canonique d'une loi normale multivariée :

$$w \mid y, \beta \sim \mathcal{N}(\mu_{\text{post}}, \Sigma_{\text{post}}) \quad (3.13)$$

avec

$$Q_{\text{post}} = Q_0 + \tau^{-2} I_n \quad (3.14)$$

et

$$\Sigma_{\text{post}} = Q_{\text{post}}^{-1}. \quad (3.15)$$

La moyenne *a posteriori* est

$$\mu_{\text{post}} = Q_{\text{post}}^{-1} \tau^{-2} (y - X\beta). \quad (3.16)$$

Ainsi, la précision *a posteriori* combine deux sources d'information :

$$Q_{\text{post}} = \underbrace{Q_0}_{\text{structure spatiale}} + \underbrace{\tau^{-2} I_n}_{\text{information des observations}}.$$

Lorsque τ^2 est faible, les observations sont peu bruitées et leur contribution à la précision *a posteriori* devient plus importante. À l'inverse, lorsque τ^2 augmente, la distribution *a posteriori* est davantage influencée par la structure spatiale du prior.

La moyenne *a posteriori* réalise donc un compromis entre les observations et la structure de dépendance imposée par le champ latent.

3.4 Variance marginale et intervalles de crédibilité

La disponibilité de la covariance *a posteriori* exacte constitue un avantage important du modèle gaussien.

Pour chaque composante w_i , la variance marginale *a posteriori* est donnée par

$$\text{Var}(w_i \mid y, \beta) = [\Sigma_{\text{post}}]_{ii}. \quad (3.17)$$

L'écart-type marginal correspondant est

$$\sigma_{\text{post},i} = \sqrt{[\Sigma_{\text{post}}]_{ii}}. \quad (3.18)$$

Comme la distribution marginale de chaque composante est gaussienne,

$$w_i \mid y, \beta \sim \mathcal{N}(\mu_{\text{post},i}, \sigma_{\text{post},i}^2), \quad (3.19)$$

un intervalle de crédibilité ponctuel à 95 % est donné par

$$[\mu_{\text{post},i} - 1.96 \sigma_{\text{post},i}, \mu_{\text{post},i} + 1.96 \sigma_{\text{post},i}]. \quad (3.20)$$

Ces quantités fourniront au chapitre 5 une référence analytique pour évaluer non seulement l'estimation de la moyenne du champ latent, mais également l'estimation de son incertitude par MCMC.

3.5 Log-postérieure, gradient et courbure

Les méthodes MCMC étudiées dans la suite, en particulier MALA, exploitent le gradient de la log-densité cible.

D'après (3.10),

$$\log p(w \mid y, \beta) = -\frac{1}{2}w^\top Q_0 w - \frac{1}{2\tau^2}(y - X\beta - w)^\top (y - X\beta - w) + C. \quad (3.21)$$

Son gradient par rapport à w est

$$\boxed{\nabla_w \log p(w \mid y, \beta) = -Q_0 w + \tau^{-2}(y - X\beta - w).} \quad (3.22)$$

En utilisant la précision *a posteriori*, cette expression peut également s'écrire

$$\nabla_w \log p(w \mid y, \beta) = -Q_{\text{post}} w + \tau^{-2}(y - X\beta). \quad (3.23)$$

La Hessienne est constante :

$$\boxed{\nabla_w^2 \log p(w \mid y, \beta) = -Q_{\text{post}}.} \quad (3.24)$$

La log-postérieure est donc une fonction quadratique concave en w et sa courbure ne dépend pas de la position courante dans l'espace des états.

Cette propriété est particulièrement importante pour la suite du mémoire : dans le modèle gaussien, la géométrie de la loi *a posteriori* est entièrement décrite par la matrice constante Q_{post} .

Cette matrice fournit ainsi un préconditionnement naturel et constitue une référence pour étudier l'effet de l'adaptation de la géométrie dans les algorithmes MCMC.

3.6 Rôle du modèle gaussien dans l'étude

Le modèle gaussien joue un double rôle dans ce mémoire.

D'une part, la connaissance analytique de

$$\mu_{\text{post}} \quad \text{et} \quad \Sigma_{\text{post}}$$

permet de vérifier que les estimations produites par MCMC convergent vers les bonnes caractéristiques de la distribution cible.

La moyenne MCMC pourra ainsi être comparée à μ_{post} , tandis que les variances marginales estimées pourront être comparées aux éléments diagonaux de Σ_{post} .

D'autre part, la Hessienne constante

$$-Q_{\text{post}}$$

fournit la géométrie exacte de la cible. Il est donc possible d'étudier directement l'effet d'un préconditionnement construit à partir du prior Q_0 ou de la précision *a posteriori* exacte Q_{post} .

Cette situation servira ensuite de point de comparaison avec les modèles non gaussiens. Dans les modèles binaire et de Poisson étudiés aux chapitres suivants, la courbure de la log-postérieure dépend du champ latent et ne peut plus être représentée par une matrice constante connue analytiquement.

Conclusion

Le modèle géostatistique gaussien présente l'avantage de conduire à une loi *a posteriori* explicite du champ latent.

Sa moyenne

$$\mu_{\text{post}}$$

et sa covariance

$$\Sigma_{\text{post}} = Q_{\text{post}}^{-1}$$

peuvent être calculées directement. Elles fournissent ainsi des références exactes pour évaluer les estimations de la moyenne et de la variance obtenues par MCMC.

Par ailleurs, la Hessienne constante

$$-Q_{\text{post}}$$

permet de connaître exactement la géométrie de la distribution cible. Le modèle gaussien constitue donc à la fois un cadre de validation de l'implémentation MCMC et un cas de référence pour étudier l'effet du préconditionnement.

Le chapitre suivant présente les méthodes d'échantillonnage utilisées pour explorer cette distribution, avant leur évaluation numérique dans le chapitre 5.

Chapitre 4

Méthodes de Monte Carlo par chaînes de Markov

Dans le modèle géostatistique gaussien présenté au chapitre précédent, la distribution *a posteriori* du champ latent possède une expression analytique. Cette situation constitue toutefois un cas particulier. Lorsque la vraisemblance n'est plus gaussienne, comme dans les modèles binaire et de Poisson étudiés par la suite, la distribution *a posteriori* ne peut plus être simulée directement.

Les méthodes de Monte Carlo par chaînes de Markov (MCMC) permettent de construire une chaîne dont la distribution stationnaire est la distribution cible. Leur intérêt ne dépend cependant pas uniquement de cette propriété : dans les problèmes de grande dimension, il est également nécessaire que la chaîne explore efficacement les différentes régions de forte probabilité.

Ce chapitre présente d'abord les principes de Metropolis–Hastings et de MALA. Trois mécanismes étudiés dans ce mémoire sont ensuite introduits : l'adaptation du pas de proposition, le préconditionnement et la persistance du momentum. Enfin, les principaux critères utilisés pour comparer les chaînes sont présentés.

4.1 Principe des méthodes MCMC

Les méthodes MCMC permettent d'obtenir des échantillons d'une distribution cible π lorsque celle-ci ne peut pas être simulée directement. Le principe consiste à construire une chaîne de Markov

$$w^{(0)}, w^{(1)}, \dots, w^{(N)}$$

dont la distribution stationnaire est la distribution d'intérêt, ici

$$\pi(w) = p(w \mid y, \beta).$$

Sous des conditions appropriées d'ergodicité, la distribution de la chaîne converge vers π . Après une phase transitoire, les valeurs de la chaîne peuvent alors être utilisées pour estimer des espérances sous la distribution cible. Par exemple,

$$\mathbb{E}_\pi[f(w)] \approx \frac{1}{N} \sum_{t=1}^N f(w^{(t)}). \quad (4.1)$$

Une phase initiale, appelée *burn-in*, est généralement écartée afin de réduire l'influence de l'état initial.

Contrairement à des simulations indépendantes, les états successifs d'une chaîne MCMC sont corrélés. Deux algorithmes ciblant correctement la même distribution peuvent donc présenter des efficacités très différentes.

L'objectif est ainsi double : construire une chaîne ayant la bonne distribution stationnaire et limiter suffisamment l'autocorrélation pour obtenir des estimations Monte-Carlo précises avec un nombre raisonnable d'itérations.

4.2 Algorithme de Metropolis–Hastings

L'algorithme de Metropolis–Hastings construit une chaîne de Markov à partir d'une distribution de proposition q . À l'itération t , un candidat w^* est simulé selon

$$w^* \sim q(\cdot \mid w^{(t)}).$$

Il est accepté avec la probabilité

$$\alpha(w^{(t)}, w^*) = \min \left(1, \frac{\pi(w^*)q(w^{(t)} \mid w^*)}{\pi(w^{(t)})q(w^* \mid w^{(t)})} \right). \quad (4.2)$$

En cas d'acceptation,

$$w^{(t+1)} = w^*,$$

et sinon

$$w^{(t+1)} = w^{(t)}.$$

La correction de Metropolis–Hastings permet ainsi de préserver la distribution cible, sous les conditions usuelles de régularité de la chaîne.

L'efficacité de la méthode dépend cependant fortement de la proposition. Une proposition trop locale conduit à une exploration lente, tandis qu'une proposition trop éloignée de l'état courant peut entraîner de nombreux rejets.

MALA améliore cette construction en exploitant le gradient de la log-densité cible.

4.3 Algorithme Metropolis–Adjusted Langevin (MALA)

MALA exploite le gradient de la log-densité cible afin d'orienter les propositions vers les régions de forte probabilité. Il est obtenu à partir de la diffusion de Langevin

$$dW_t = \frac{1}{2} \nabla \log \pi(W_t) dt + dB_t, \quad (4.3)$$

où B_t désigne un mouvement brownien.

Une discrétisation d'Euler–Maruyama conduit à la proposition

$$w^* = w^{(t)} + \frac{s^2}{2} \nabla \log \pi(w^{(t)}) + sz, \quad z \sim \mathcal{N}(0, I_n), \quad (4.4)$$

où $s > 0$ désigne le pas de proposition.

Conditionnellement à $w^{(t)}$, le candidat suit donc

$$q(w^* \mid w^{(t)}) = \mathcal{N} \left(w^{(t)} + \frac{s^2}{2} \nabla \log \pi(w^{(t)}), s^2 I_n \right). \quad (4.5)$$

La présence du gradient rend la proposition asymétrique. Une correction de Metropolis–Hastings est donc appliquée :

$$\alpha = \min \left(1, \frac{\pi(w^*)q(w^{(t)} \mid w^*)}{\pi(w^{(t)})q(w^* \mid w^{(t)})} \right). \quad (4.6)$$

Par rapport à une marche aléatoire, le gradient fournit une information sur la géométrie locale de la distribution cible. MALA reste néanmoins sensible au choix du pas de proposition et aux différences d'échelle entre les directions de la cible.

4.4 Difficultés de MALA

Le premier paramètre critique est le pas s . Lorsque celui-ci est trop petit, les propositions sont fréquemment acceptées mais les déplacements restent de faible amplitude. Les échantillons successifs sont alors fortement corrélés.

À l'inverse, un pas trop grand produit des déplacements plus importants mais augmente le risque de rejet. Dans les deux situations, l'efficacité de l'échantillonnage se dégrade.

Sous certaines hypothèses asymptotiques, Roberts et Rosenthal [Roberts and Rosenthal, 1998] obtiennent pour MALA un taux d'acceptation optimal proche de

$$0.574.$$

Cette valeur constitue un repère pour le réglage de MALA, mais ne doit pas être interprétée comme une valeur optimale universelle pour toutes les dimensions, toutes les distributions cibles ou toutes les variantes de l'algorithme.

Une seconde difficulté apparaît lorsque la distribution cible est fortement anisotrope. Des corrélations importantes ou des échelles différentes selon les directions peuvent rendre une proposition isotrope mal adaptée à la géométrie de la cible.

Les trois mécanismes étudiés dans ce mémoire répondent à ces difficultés :

- l'adaptation automatique du pas agit sur l'échelle globale des déplacements ;
- le préconditionnement adapte les déplacements à la géométrie de la cible ;
- la persistance du momentum vise à conserver une partie de la direction du déplacement entre deux itérations successives.




FIGURE 4.1 – Influence du pas de proposition sur le comportement de MALA. Un pas trop faible conduit à des déplacements limités, tandis qu'un pas trop grand augmente le nombre de rejets.

4.5 Adaptation du pas de proposition

Afin de limiter le réglage manuel du pas, celui-ci est adapté pendant la phase de *burn-in* à l'aide d'une procédure de type Robbins–Monro [Robbins and Monro, 1951].

La mise à jour utilisée est

$$\log(s_{t+1}) = \log(s_t) + \gamma_t(A_t - \alpha^*), \quad (4.7)$$

où $A_t = 1$ si la proposition est acceptée et $A_t = 0$ sinon, α^* désigne le taux d'acceptation cible et γ_t contrôle l'amplitude de l'adaptation.

Dans l'implémentation retenue,

$$\gamma_t = \frac{1}{(t+10)^{0.6}}. \quad (4.8)$$

La diminution de γ_t réduit progressivement l'amplitude des modifications du pas.

Pour MALA, le taux cible utilisé est

$$\alpha^* = 0.574. \quad (4.9)$$

La même valeur est utilisée comme réglage pratique dans la variante avec momentum introduite plus loin. Dans ce dernier cas, elle doit être considérée comme un choix algorithmique inspiré du réglage asymptotique de MALA, et non comme un taux optimal théoriquement établi pour cette variante.

L'adaptation est limitée à la phase de *burn-in*. Le pas obtenu à la fin de cette phase est ensuite maintenu constant pendant la partie de la chaîne utilisée pour l'inférence.




FIGURE 4.2 – Exemple d'évolution du pas de proposition pendant la phase de *burn-in*.

4.6 Préconditionnement

L'adaptation du pas agit sur l'échelle globale de la proposition, mais ne corrige pas les différences de géométrie entre les directions de la distribution cible.

Pour prendre en compte ces différences, on introduit une matrice symétrique définie positive M . Le MALA préconditionné utilise la proposition

$$w^* = w^{(t)} + \frac{s^2}{2} M \nabla \log \pi(w^{(t)}) + s M^{1/2} z, \quad z \sim \mathcal{N}(0, I_n). \quad (4.10)$$

Conditionnellement à $w^{(t)}$, la covariance de la proposition est

$$s^2 M.$$

La matrice M agit donc à la fois sur le terme déterministe associé au gradient et sur le bruit de proposition.

Lorsque M est proche de la covariance de la distribution cible, le préconditionnement réduit les différences d'échelle entre les directions et facilite l'exploration de la cible.

Dans ce mémoire, les matrices utilisées pour construire M sont exprimées plus naturellement sous forme de matrices de précision. Si C désigne une matrice de précision choisie comme métrique, on pose

$$\boxed{M = C^{-1}}. \quad (4.11)$$

L'algorithme n'a cependant pas besoin de former explicitement cette inverse : les produits par M sont obtenus par résolution de systèmes linéaires impliquant C .

Dans le modèle gaussien, trois choix sont notamment considérés :

$$C_{\text{Id}} = I_n, \quad (4.12)$$

$$C_{\text{prior}} = Q_0, \quad (4.13)$$

et

$$C_{\text{post}} = Q_{\text{post}}. \quad (4.14)$$

Les matrices de préconditionnement correspondantes sont donc respectivement

$$I_n, \quad Q_0^{-1}, \quad Q_{\text{post}}^{-1}.$$

Dans les modèles non gaussiens, la précision postérieure exacte n'est plus disponible. Le préconditionnement fondé sur la géométrie postérieure est alors remplacé par une approximation construite à partir de la courbure de la log-postérieure évaluée au MAP.

La proposition reste corrigée par une étape de Metropolis afin de préserver la distribution cible.

Efficacité numérique du préconditionnement

Les matrices de précision utilisées dans les expériences sont creuses grâce à l'approximation de Vecchia. Cette structure joue un rôle essentiel dans l'efficacité numérique de la méthode.

Pour une matrice symétrique définie positive C , on utilise une factorisation de Cholesky

$$C = LL^\top, \quad (4.15)$$

où L est triangulaire inférieure.

Pour calculer

$$C^{-1}b,$$

il n'est pas nécessaire de former explicitement C^{-1} . On résout successivement

$$Ly = b, \quad (4.16)$$

puis

$$L^\top x = y. \quad (4.17)$$

On obtient alors

$$x = C^{-1}b.$$

Cette distinction est importante : les préconditionnements sont définis mathématiquement à partir de matrices inverses, mais leur implémentation repose uniquement sur des résolutions de systèmes linéaires.

Lorsque C est creuse, une factorisation de Cholesky creuse permet de réduire fortement le coût mémoire et le temps de calcul par rapport à une factorisation dense, même si la quantité de remplissage dépend de la structure de la matrice et de l'ordre utilisé.

Cette approche est particulièrement adaptée aux modèles spatiaux de grande dimension. Elle permet d'effectuer les calculs de préconditionnement et les résolutions nécessaires à l'algorithme sans former explicitement les grandes matrices inverses [Rue and Held, 2005].




FIGURE 4.3 – Effet schématique du préconditionnement sur la géométrie de la distribution cible. Sans préconditionnement, les différences d'échelle limitent les déplacements ; une métrique adaptée permet de rééquilibrer les directions d'exploration.

L'adaptation de la géométrie des propositions est également au cœur de méthodes utilisant une métrique dépendant de la position dans l'espace des états [Girolami and Calderhead, 2011]. Dans le présent travail, la matrice de préconditionnement est au contraire maintenue fixe au cours de chaque chaîne.

4.7 Variante à momentum inspirée des méthodes hamiltoniennes

Une autre manière de modifier la dynamique de la chaîne consiste à introduire une variable auxiliaire portant une information sur la direction du déplacement. Cette idée est inspirée des méthodes de Monte Carlo hamiltonien [Neal, 2011].

La méthode étudiée dans ce mémoire ne correspond pas à un HMC classique reposant sur une trajectoire constituée de plusieurs étapes de Leapfrog. Elle utilise une seule étape de Leapfrog à chaque itération et un rafraîchissement partiel du momentum.

Dans la suite, cette méthode est appelée *MALA avec momentum*, en raison du lien présenté plus loin avec le MALA préconditionné lorsque le momentum est entièrement renouvelé.

4.7.1 Distribution augmentée

On introduit un momentum p de même dimension que le champ latent, suivant

$$p \sim \mathcal{N}(0, C), \quad (4.18)$$

où C est une matrice symétrique définie positive.

La distribution augmentée sur (w, p) est associée à l'hamiltonien

$$H(w, p) = -\log \pi(w) + \frac{1}{2} p^\top C^{-1} p. \quad (4.19)$$

Le premier terme correspond à l'énergie potentielle associée à la distribution cible et le second à l'énergie cinétique du momentum.

Dans cette formulation, la matrice C joue le rôle d'une matrice de masse. Le préconditionnement marginal du champ latent est donné par

$$M = C^{-1}.$$

4.7.2 Rafraîchissement partiel du momentum

Le momentum est d'abord mis à jour selon

$$p_{\text{ref}} = \rho p^{(t)} + \sqrt{1 - \rho^2} \xi, \quad \xi \sim \mathcal{N}(0, C), \quad (4.20)$$

où

$$0 \leq \rho < 1$$

contrôle la persistance du momentum.

Pour

$$\rho = 0,$$

le momentum est entièrement renouvelé à chaque itération.

Lorsque ρ augmente, une fraction plus importante du momentum précédent est conservée. La valeur ρ détermine donc le degré de mémoire de la direction de déplacement entre deux itérations successives.

4.7.3 Étape de Leapfrog

À partir de $(w^{(t)}, p_{\text{ref}})$, une seule étape de Leapfrog est effectuée :

$$p_{1/2} = p_{\text{ref}} + \frac{\varepsilon}{2} \nabla \log \pi(w^{(t)}), \quad (4.21)$$

$$w^\star = w^{(t)} + \varepsilon C^{-1} p_{1/2}, \quad (4.22)$$

$$p^\star = p_{1/2} + \frac{\varepsilon}{2} \nabla \log \pi(w^\star). \quad (4.23)$$

Le paramètre ε joue ici le rôle du pas d'intégration.

4.7.4 Lien avec MALA préconditionné

Le lien avec MALA apparaît lorsque le momentum est entièrement renouvelé, c'est-à-dire lorsque

$$\rho = 0.$$

Dans ce cas,

$$p_{\text{ref}} \sim \mathcal{N}(0, C).$$

La mise à jour de w devient

$$w^\star = w^{(t)} + \varepsilon C^{-1} \left[p_{\text{ref}} + \frac{\varepsilon}{2} \nabla \log \pi(w^{(t)}) \right] \quad (4.24)$$

$$= w^{(t)} + \frac{\varepsilon^2}{2} C^{-1} \nabla \log \pi(w^{(t)}) + \varepsilon C^{-1} p_{\text{ref}}. \quad (4.25)$$

Or,

$$C^{-1} p_{\text{ref}} \sim \mathcal{N}(0, C^{-1}).$$

La proposition marginale pour w s'écrit donc

$$w^\star \sim \mathcal{N}\left(w^{(t)} + \frac{\varepsilon^2}{2} C^{-1} \nabla \log \pi(w^{(t)}), \varepsilon^2 C^{-1}\right). \quad (4.26)$$

Elle correspond exactement à la structure d'un MALA préconditionné avec

$$M = C^{-1} \quad (4.27)$$

et

$$s = \varepsilon. \quad (4.28)$$

Lorsque $\rho > 0$, le momentum n'est plus indépendant d'une itération à la suivante. La méthode étend alors cette dynamique en conservant une partie de la direction précédente.

Ce lien justifie la terminologie *MALA avec momentum* utilisée dans le reste du mémoire.

4.7.5 Correction de Metropolis

Après l'étape de Leapfrog, la proposition augmentée $(w^\star, p^\star)$ est acceptée avec la probabilité

$$\alpha = \min \left[1, \exp \left\{ -H(w^\star, p^\star) + H(w^{(t)}, p_{\text{ref}}) \right\} \right]. \quad (4.29)$$

En cas d'acceptation,

$$w^{(t+1)} = w^\star, \quad p^{(t+1)} = p^\star.$$

En cas de rejet,

$$w^{(t+1)} = w^{(t)}, \quad p^{(t+1)} = -p_{\text{ref}}.$$

Le changement de signe du momentum en cas de rejet permet de conserver la réversibilité de la dynamique augmentée.

Comme précédemment, le pas ε est adapté uniquement pendant le *burn-in*, puis fixé pendant la phase utilisée pour l'inférence.

4.8 Critères d'évaluation des chaînes

L'efficacité des méthodes est principalement évaluée à partir du taux d'acceptation et de la taille effective d'échantillon (*Effective Sample Size*, ESS).

Le taux d'acceptation mesure la proportion de propositions acceptées. Il constitue un indicateur du réglage du pas, mais ne suffit pas à lui seul pour évaluer l'efficacité d'une chaîne. Un taux très élevé peut en effet correspondre à des déplacements très faibles et donc à une forte autocorrélation.

L'ESS tient compte de cette autocorrélation. Pour une chaîne stationnaire de longueur N , on peut écrire formellement

$$\text{ESS} = \frac{N}{1 + 2 \sum_{k=1}^{\infty} \rho_k}, \quad (4.30)$$

où ρ_k désigne l'autocorrélation au retard k . En pratique, cette quantité est estimée à partir d'un nombre fini d'autocorrélations.

Une valeur élevée de l'ESS signifie qu'une chaîne contient davantage d'information effective pour un même nombre d'itérations. L'ESS constitue donc le principal indicateur d'efficacité statistique utilisé dans les expériences.

Pour un champ latent de dimension n , un ESS peut être calculé pour chaque composante. Plusieurs résumés sont alors considérés :

- l'ESS moyen ;
- l'ESS médian, utilisé comme indicateur principal de performance ;
- l'ESS minimal, qui renseigne sur les composantes les plus difficiles à échantillonner ;
- l'ESS maximal.

Dans les expériences non gaussiennes de dimension $n = 10\,000$, l'ESS est calculé sur un sous-ensemble de 100 composantes régulièrement réparties dans le champ latent afin de limiter le stockage des trajectoires.

En revanche, les moyennes et variances marginales postérieures sont calculées sur l'ensemble des composantes du champ.

Enfin, les performances statistiques sont mises en regard du coût numérique. Le temps d'exécution est notamment enregistré dans les expériences factorielles afin de vérifier qu'un gain d'ESS ne s'accompagne pas d'un coût de calcul disproportionné.

Conclusion

Ce chapitre a présenté les méthodes d'échantillonnage étudiées dans ce mémoire.

MALA exploite le gradient de la log-densité cible afin de guider les propositions, mais son efficacité dépend du réglage du pas et de l'adéquation entre la géométrie de la proposition et celle de la distribution cible.

L'adaptation de Robbins–Monro permet d'ajuster automatiquement le pas pendant le *burn-in*. Le préconditionnement introduit quant à lui une matrice destinée à réduire les différences d'échelle entre les directions de la cible. Dans l'implémentation utilisée, cette opération repose sur des matrices de précision creuses et sur des résolutions de systèmes linéaires, sans calcul explicite des inverses.

La variante à momentum complète ces mécanismes en introduisant une mémoire de la direction entre deux itérations successives. Lorsque le momentum est entièrement renouvelé et qu'une seule étape de Leapfrog est utilisée, la proposition marginale du champ latent retrouve exactement la structure d'un MALA préconditionné. Une valeur $\rho > 0$ introduit une persistance supplémentaire du momentum.

Le chapitre suivant évalue expérimentalement l'effet du préconditionnement et de cette persistance dans le modèle géostatistique gaussien, en utilisant la distribution *a posteriori* analytique comme référence.

Chapitre 5

Expériences numériques sur le modèle gaussien

Ce chapitre présente les expériences numériques réalisées sur le modèle géostatistique gaussien. L'objectif est double : vérifier que les méthodes MCMC implémentées reproduisent correctement les caractéristiques de la loi *a posteriori*, connue analytiquement dans ce cas, puis identifier une stratégie MALA à la fois performante et robuste lorsque les paramètres du modèle et de l'algorithme varient.

Le modèle gaussien constitue ainsi un cadre contrôlé permettant, d'une part, de valider l'implémentation et, d'autre part, d'étudier l'influence du préconditionnement et de la persistance du momentum sur l'efficacité de l'échantillonnage.

La disponibilité d'une solution analytique permet également d'aller au-delà de la seule estimation de la moyenne du champ latent. Les variances marginales *a posteriori* estimées à partir des chaînes peuvent être comparées à leurs valeurs exactes. Cette analyse permet d'évaluer la précision Monte-Carlo avec laquelle les différentes stratégies reproduisent la dispersion de la distribution cible.

5.1 Protocole expérimental

Génération des données et réglage des chaînes

Les expériences sont réalisées sur un domaine spatial bidimensionnel contenant

$$n = 1000$$

sites.

Pour chaque réalisation, les positions spatiales sont générées sur le domaine, puis une matrice de régression est construite sous la forme

$$X = \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix},$$

où la seconde covariable est simulée selon une loi normale centrée réduite.

Les coefficients de régression sont fixés à

$$\beta = \begin{pmatrix} 1 \\ 0.01 \end{pmatrix}.$$

La structure de dépendance spatiale est approchée par la méthode de Vecchia avec six voisins. La factorisation creuse obtenue définit la précision *a priori*

$$Q_0 = \tilde{R}^\top \tilde{R}.$$

Afin de distinguer plus clairement le rôle du paramètre de régularité ν de celui de l'échelle spatiale, les expériences sont paramétrées à partir de

$$\ell^\star = \frac{\ell}{\sqrt{\nu}}.$$

Le champ latent est simulé selon

$$w = \tilde{R}^{-1}z, \quad z \sim \mathcal{N}(0, I_n),$$

puis les observations sont générées à partir de

$$y = X\beta + w + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \tau^2 I_n).$$

Pour chaque configuration, une chaîne de 10 000 itérations est générée. Les 2 000 premières constituent la phase de *burn-in*, pendant laquelle le pas est adapté par la procédure décrite au chapitre 4.

L'adaptation est ensuite arrêtée et les 8 000 itérations restantes sont utilisées pour calculer les estimations *a posteriori* et les diagnostics MCMC.

Trois stratégies de préconditionnement sont comparées.

TABLE 5.1 – Stratégies de préconditionnement considérées dans le modèle gaussien.

Code	Stratégie	Précision utilisée	Préconditionneur
0	Identité	I_n	I_n
1	A priori	Q_0	Q_0^{-1}
2	A posteriori	$Q_{\text{post}} = Q_0 + \tau^{-2}I_n$	Q_{post}^{-1}

Plan factoriel

Afin d'étudier la sensibilité des performances aux paramètres du modèle et de l'algorithme, une expérience factorielle est réalisée.

Les facteurs considérés sont la régularité ν , la variance du bruit τ^2 , l'échelle spatiale reparamétrée $\ell^\star$, la persistance du momentum ρ et la stratégie de préconditionnement.

TABLE 5.2 – Paramètres considérés dans l'expérience factorielle gaussienne.

Paramètre	Valeurs testées
Régularité ν	0.5, 1.5
Variance du bruit τ^2	0.1, 1, 5
Échelle spatiale $\ell^\star$	0.02, 0.05
Persistance ρ	0, 0.5, 0.9
Préconditionnement	identité, a priori, a posteriori
Répétitions	5

Le plan complet comporte

$$2 \times 3 \times 2 \times 3 \times 3 \times 5 = 540$$

chaînes MCMC.

Pour une combinaison donnée de paramètres du modèle et une même graine aléatoire, les différentes stratégies sont appliquées au même jeu de données simulé. Les comparaisons portent ainsi sur l'algorithme d'échantillonnage et non sur des réalisations différentes du problème.

Les cinq graines permettent de prendre en compte la variabilité liée à la simulation des positions, du champ latent, des covariables et du bruit. La graine n'est pas considérée comme un paramètre scientifique du modèle ; elle est introduite uniquement comme facteur de contrôle dans l'analyse statistique.

Critères de comparaison

Pour chaque chaîne, plusieurs diagnostics sont enregistrés :

- le taux d'acceptation après le *burn-in* ;
- le pas final ;
- l'ESS moyen, médian, minimal et maximal ;
- les estimations de la moyenne et de la variance marginales *a posteriori*.

Un ESS est calculé pour chaque composante du champ latent. L'ESS médian est retenu comme indicateur principal d'efficacité, car il fournit un résumé robuste des performances globales de la chaîne. L'ESS minimal permet d'identifier les composantes les plus difficiles à échantillonner.

La distribution *a posteriori* étant connue analytiquement, les estimations MCMC peuvent également être comparées aux quantités exactes.

Pour la moyenne, on utilise

$$\text{RMSE}_\mu = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{\mu}_i - \mu_{\text{post},i})^2}. \quad (5.1)$$

Pour les variances marginales,

$$\text{RMSE}_{\text{var}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{v}_i - v_i)^2}, \quad (5.2)$$

où

$$v_i = [\Sigma_{\text{post}}]_{ii}.$$

L'erreur relative moyenne est définie par

$$\text{ER}_{\text{var}} = \frac{1}{n} \sum_{i=1}^n \frac{|\hat{v}_i - v_i|}{v_i}. \quad (5.3)$$

Enfin, des intervalles ponctuels à 95 % sont construits à partir des estimations MCMC afin d'étudier leur couverture empirique et leur largeur moyenne.

L'évaluation des stratégies repose donc sur trois dimensions complémentaires : l'efficacité de l'échantillonnage, la précision de l'estimation de la moyenne et la précision de l'estimation de l'incertitude.

5.2 Validation par la solution analytique

L'un des principaux intérêts du modèle gaussien est que la distribution *a posteriori* du champ latent est connue exactement :

$$w \mid y \sim \mathcal{N}(\mu_{\text{post}}, \Sigma_{\text{post}}).$$

Cette propriété permet de vérifier que les chaînes MCMC fournissent, pour une longueur de chaîne donnée, des estimations compatibles avec les quantités analytiques.

Une première validation est réalisée sur une configuration représentative, les trois stratégies étant appliquées aux mêmes données simulées.

TABLE 5.3 – Comparaison des estimations MCMC à la solution analytique sur une configuration de référence.

Préconditionnement	RMSE $_{\mu}$	RMSE $_{\sigma}$	ESS médian	ESS min.
Identité	0.1767	0.0854	38.21	11.25
A priori	0.0458	0.0312	429.56	250.94
A posteriori	0.0468	0.0334	381.97	200.12

Les trois stratégies visent théoriquement la même distribution *a posteriori*. Les différences observées dans le Tableau 5.3 reflètent donc principalement la précision Monte-Carlo obtenue pour une longueur de chaîne fixée.

Avec la matrice identité, l'ESS médian n'est que d'environ 38 pour 8 000 itérations conservées. Cette faible taille effective traduit une forte autocorrélation et conduit à des estimations plus éloignées des quantités analytiques.

À l'inverse, les stratégies préconditionnées conduisent à des ESS nettement supérieurs et à des erreurs beaucoup plus faibles sur la moyenne et les écarts-types marginaux.


Cette comparaison confirme le bon fonctionnement de l'implémentation et montre l'intérêt du préconditionnement pour améliorer la précision Monte-Carlo à budget d'itérations fixé.

5.3 Résultats sur le champ latent et son incertitude


Avant d'étudier les performances globales sur l'ensemble du plan factoriel, on examine la reconstruction du champ latent dans trois situations représentatives.

La Figure 5.1 présente, pour chaque configuration, les observations, le champ latent simulé, la moyenne *a posteriori* estimée et la variance marginale *a posteriori* estimée.


La variance doit être interprétée comme une mesure de dispersion de la distribution *a posteriori* autour de sa moyenne. Elle ne constitue donc pas une carte de l'erreur de reconstruction.



Configuration 1 : $\nu = 1.5$, $\ell^* = 0.05$, $\tau^2 = 0.1$ — champ régulier, faible bruit



Configuration 2 : $\nu = 0.5$, $\ell^* = 0.02$, $\tau^2 = 1$ — champ moins régulier, échelle courte



Configuration 3 : $\nu = 1.5$, $\ell^* = 0.05$, $\tau^2 = 5$ — observations fortement bruitées

FIGURE 5.1 – Observations, champ latent simulé, moyenne *a posteriori* et variance marginale *a posteriori* estimées pour trois configurations du modèle géostatistique gaussien.

Les trois configurations illustrent des situations de difficulté croissante.

Dans la première configuration, ($\nu = 1.5, \ell^* = 0.05, \tau^2 = 0.1$), le bruit d'observation est faible. Les observations restent proches du champ latent et sa structure spatiale est nettement visible. La moyenne *a posteriori* reproduit donc fidèlement les principales variations du champ.

La deuxième configuration, ($\nu = 0.5, \ell^* = 0.02, \tau^2 = 1$), combine une régularité plus faible, une échelle spatiale plus courte et un bruit plus important. Le champ présente davantage de fluctuations locales et la reconstruction devient plus difficile. La moyenne *a posteriori* restitue néanmoins l'organisation générale du champ, tout en régularisant certaines variations locales.

La troisième configuration reprend les mêmes paramètres spatiaux que la première mais avec

$$\tau^2 = 5.$$

Elle permet ainsi d'isoler l'effet du bruit d'observation. Les observations deviennent fortement bruitées et masquent une partie de la structure du champ latent. La moyenne *a posteriori* réduit cette variabilité grâce à la combinaison de l'information observationnelle et de la dépendance

spatiale.

Les cartes de variance montrent parallèlement que l'incertitude *a posteriori* augmente lorsque les observations deviennent moins informatives. Cette évolution est particulièrement visible lorsque l'on compare les première et troisième configurations.

Les échelles graphiques étant adaptées séparément, la comparaison quantitative des niveaux de variance doit toutefois reposer sur les valeurs numériques des légendes plutôt que sur les couleurs seules.

5.4 Précision de l'estimation de l'incertitude postérieure

La reconstruction correcte de la moyenne ne garantit pas, à elle seule, une estimation précise de l'ensemble de la distribution *a posteriori*.

Le modèle gaussien permet d'étudier directement cette question puisque

$$\Sigma_{\text{post}} = Q_{\text{post}}^{-1}$$

est connue analytiquement.

Pour chacune des 540 chaînes, les variances marginales estimées par MCMC sont donc comparées aux éléments diagonaux exacts de Σ_{post} .

La Figure 5.2 présente la distribution de RMSE_{var} en fonction de ρ et de la stratégie de préconditionnement.




FIGURE 5.2 – Distribution de la RMSE entre les variances marginales *a posteriori* estimées par MCMC et leurs valeurs analytiques, selon la persistance du momentum et la stratégie de préconditionnement.

Le Tableau 5.4 résume les principaux résultats.

TABLE 5.4 – Précision moyenne de l'estimation de l'incertitude *a posteriori* selon la stratégie MALA.

Stratégie	ρ	RMSE _{var}	ER _{var}	Couverture	Largeur
Identité	0	0.12130	0.30140	0.8117	1.7125
Identité	0.5	0.10453	0.25403	0.8446	1.7916
Identité	0.9	0.09081	0.21685	0.8756	1.8664
A priori	0	0.02120	0.06994	0.9423	2.0531
A priori	0.5	0.01796	0.05726	0.9440	2.0580
A priori	0.9	0.02389	0.06397	0.9441	2.0586
A posteriori	0	0.01801	0.04375	0.9455	2.0601
A posteriori	0.5	0.01597	0.03875	0.9465	2.0609
A posteriori	0.9	0.02661	0.06468	0.9450	2.0577

La stratégie identité se distingue nettement des deux stratégies préconditionnées.

Sa RMSE moyenne reste comprise entre environ 0.091 et 0.121, tandis que l'erreur relative moyenne varie entre environ 21.7 % et 30.1 %.

L'augmentation de ρ améliore progressivement la précision pour cette stratégie, mais les erreurs restent nettement supérieures à celles obtenues avec préconditionnement.

Avec le préconditionnement *a priori*, la RMSE moyenne est ramenée entre environ 0.018 et 0.024, et l'erreur relative moyenne entre environ 5.7 % et 7.0 %.

Le préconditionnement *a posteriori* conduit également à de faibles erreurs. La combinaison

$$\text{a posteriori} + \rho = 0.5$$

présente la plus faible RMSE moyenne :

$$\text{RMSE}_{\text{var}} = 0.01597,$$

ainsi que la plus faible erreur relative moyenne :

$$\text{ER}_{\text{var}} = 0.03875.$$

L'analyse des intervalles ponctuels conduit à une lecture cohérente.

Avec la stratégie identité, la proportion moyenne de sites pour lesquels le champ simulé appartient à l'intervalle ponctuel estimé est comprise entre environ 81.2 % et 87.6 %.

Les stratégies préconditionnées atteignent des proportions proches de 95 %, comprises entre environ 94.2 % et 94.6 %.

La combinaison *a posteriori* avec $\rho = 0.5$ atteint ainsi

$$94.65 \%$$

pour une largeur moyenne de

$$2.061.$$

Cette valeur doit toutefois être interprétée comme une mesure descriptive de couverture empirique sur les sites simulés. Les composantes du champ sont spatialement dépendantes ; il ne s'agit donc pas de n répétitions indépendantes d'une expérience fréquentiste.

La comparaison reste néanmoins informative pour confronter les stratégies sur un même ensemble de réalisations simulées.

Le fait que les largeurs moyennes soient presque identiques entre les stratégies préconditionnées montre par ailleurs que les différences de couverture ne proviennent pas simplement d'intervalles artificiellement plus larges.

Dans l'ensemble, ces résultats montrent qu'un mauvais mélange peut affecter non seulement l'estimation de la moyenne, mais également celle de la dispersion de la cible pour une longueur de chaîne finie.

5.5 Analyse de l'efficacité de l'échantillonnage

L'analyse précédente met en évidence un lien clair entre efficacité de l'échantillonnage et précision Monte-Carlo.

On étudie maintenant plus directement la distribution de l'ESS médian sur l'ensemble du plan factoriel.

L'objectif n'est pas d'identifier la stratégie donnant ponctuellement le plus grand ESS, mais de rechercher une stratégie à la fois performante et robuste, c'est-à-dire capable de maintenir un niveau d'efficacité élevé lorsque les paramètres du modèle changent.

5.5.1 Performance et robustesse des stratégies

La Figure 5.3 présente la distribution de l'ESS médian en fonction de la persistance ρ et du préconditionnement.




FIGURE 5.3 – Distribution de l'ESS médian selon la persistance du momentum et la stratégie de préconditionnement.

Le Tableau 5.5 résume les neuf combinaisons.

TABLE 5.5 – Résumé de l’ESS médian selon la stratégie MALA.

Stratégie	ρ	Moyenne	Médiane	Écart-type	Q_{10}	Minimum
Identité	0	65.69	24.35	87.96	5.59	4.38
Identité	0.5	101.30	39.05	134.94	6.64	5.13
Identité	0.9	111.94	68.98	130.44	8.03	5.92
A priori	0	235.02	221.46	129.33	53.49	49.38
A priori	0.5	341.66	307.32	187.68	78.88	63.88
A priori	0.9	331.66	337.16	155.20	102.82	88.77
A posteriori	0	348.65	348.43	1.75	346.28	345.46
A posteriori	0.5	518.35	529.55	27.84	482.35	477.02
A posteriori	0.9	354.09	346.86	87.87	241.47	171.59

Le préconditionnement améliore nettement l’efficacité par rapport à l’identité.

La stratégie *a priori* peut conduire à des ESS élevés, mais sa dispersion reste importante. Pour $\rho = 0.5$, l’écart-type de l’ESS médian atteint environ 188 et Q_{10} reste inférieur à 80.

À l’inverse, le préconditionnement *a posteriori* présente une stabilité nettement plus forte.

Avec $\rho = 0$, l’ESS médian est déjà proche de 348 avec une dispersion très faible.

La combinaison

$$\text{a posteriori} + \rho = 0.5$$

présente les meilleures performances globales :

$$\text{ESS médian global} \simeq 529.6,$$

$$Q_{10} \simeq 482.4,$$

et

$$\text{min} \simeq 477.0.$$

Ainsi, même les configurations situées dans la partie défavorable du plan conservent un ESS élevé.

Lorsque ρ passe à 0.9, la performance moyenne reste importante mais la dispersion augmente sensiblement.

Ces résultats montrent qu’une persistance intermédiaire constitue ici un meilleur compromis qu’une persistance très élevée lorsque la géométrie de la cible est déjà bien décrite par le préconditionnement *a posteriori*.

5.5.2 Influence des paramètres du modèle

Afin d’étudier plus précisément l’influence des paramètres, un modèle linéaire est ajusté avec l’ESS médian comme variable réponse.

Le facteur *seed* est introduit comme facteur de contrôle et n’est pas interprété scientifiquement.

Le modèle considéré est

$$\begin{aligned} \text{ESS}_{\text{med}} \sim & \text{seed} + \nu + \tau^2 \times \text{prconditionnement} \\ & + \ell^* \times \text{prconditionnement} + \rho \times \text{prconditionnement}. \end{aligned} \quad (5.4)$$

Le modèle est globalement hautement significatif,

$$p < 2.2 \times 10^{-16},$$

et explique une part importante de la variabilité de l'ESS médian :

$$R^2 = 0.845, \quad R_{\text{ajust}}^2 = 0.8384.$$

```
Call:
lm(formula = ess_median ~ factor(seed) + factor(nu) + factor(tau2) *
    factor(conditioning) + factor(range) * factor(conditioning) +
    factor(rho) * factor(conditioning), data = experiment_results)

Residuals:
    Min       1Q   Median       3Q      Max
-222.03  -35.65   -1.85   33.53  393.78

Coefficients:
                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                   185.360      15.478  11.976 < 2e-16 ***
factor(seed)2                  -16.018      10.206  -1.569 0.117146
factor(seed)3                   11.474      10.206   1.124 0.261435
factor(seed)4                  -27.408      10.206  -2.685 0.007475 **
factor(seed)5                  -39.074      10.206  -3.829 0.000145 ***
factor(nu)1.5                  -26.834       6.455  -4.157 3.77e-05 ***
factor(tau2)1                 -109.708      13.692  -8.012 7.53e-15 ***
factor(tau2)5                 -134.296      13.692  -9.808 < 2e-16 ***
factor(conditioning)1          -63.386      19.364  -3.273 0.001134 **
factor(conditioning)2          186.141      19.364   9.613 < 2e-16 ***
factor(range)0.05             -38.076      11.180  -3.406 0.000711 ***
factor(rho)0.5                 30.730      13.692   2.244 0.025233 *
factor(rho)0.9                 54.968      13.692   4.014 6.84e-05 ***
factor(tau2)1:factor(conditioning)1 265.757      19.364  13.724 < 2e-16 ***
factor(tau2)5:factor(conditioning)1 472.511      19.364  24.401 < 2e-16 ***
factor(tau2)1:factor(conditioning)2 115.855      19.364   5.983 4.09e-09 ***
factor(tau2)5:factor(conditioning)2 135.571      19.364   7.001 7.92e-12 ***
factor(conditioning)1:factor(range)0.05 -26.756      15.811  -1.692 0.091203 .
factor(conditioning)2:factor(range)0.05  42.502      15.811   2.688 0.007415 **
factor(conditioning)1:factor(rho)0.5    69.610      19.364   3.595 0.000356 ***
factor(conditioning)2:factor(rho)0.5   139.799      19.364   7.219 1.88e-12 ***
factor(conditioning)1:factor(rho)0.9    39.725      19.364   2.051 0.040725 *
factor(conditioning)2:factor(rho)0.9   -38.598      19.364  -1.993 0.046754 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 75 on 517 degrees of freedom
Multiple R-squared:  0.845,    Adjusted R-squared:  0.8384
F-statistic: 128.1 on 22 and 517 DF,  p-value: < 2.2e-16
```

FIGURE 5.4 – Résultats du modèle linéaire ajusté à l'ESS médian dans le modèle gaussien.

Plusieurs effets et interactions sont statistiquement significatifs.

Pour la modalité de référence, le passage de $\nu = 0.5$ à $\nu = 1.5$ est associé à une variation estimée de

$$-26.83$$

de l'ESS médian.

L'effet de τ^2 dépend fortement du preconditionnement.

Avec la stratégie de référence, le passage de $\tau^2 = 0.1$ à $\tau^2 = 5$ est associé à un effet de

$$-134.30.$$

Pour le préconditionnement *a priori*, l'interaction correspondante vaut

$$+472.51,$$

de sorte que l'effet total estimé devient

$$-134.30 + 472.51 \simeq 338.21.$$

Pour le préconditionnement *a posteriori*, l'interaction vaut

$$+135.57,$$

et l'effet total est donc

$$-134.30 + 135.57 \simeq 1.27.$$

Le préconditionnement *a posteriori* rend ainsi l'ESS beaucoup moins sensible à la variation du bruit d'observation.

L'effet de la persistance dépend lui aussi du préconditionnement.

Pour $\rho = 0.5$, l'interaction avec le préconditionnement *a posteriori* est fortement positive :

$$+139.80.$$

Pour $\rho = 0.9$, elle devient négative :

$$-38.60.$$

Ces résultats sont cohérents avec les distributions d'ESS observées précédemment et confirment qu'une persistance intermédiaire est particulièrement favorable lorsqu'elle est associée au préconditionnement *a posteriori*.

L'échelle spatiale présente également une interaction avec le préconditionnement. Dans l'ensemble, le modèle linéaire confirme que le préconditionnement *a posteriori* réduit la sensibilité des performances à plusieurs caractéristiques du modèle.

Conclusion

Les expériences réalisées dans le modèle gaussien ont permis de valider l'implémentation dans un cadre où la distribution *a posteriori* est connue analytiquement.

Cette validation porte à la fois sur la moyenne du champ latent et sur les variances marginales *a posteriori*.

Les trois stratégies considérées ciblent théoriquement la même distribution, mais leur efficacité Monte-Carlo diffère fortement pour une longueur de chaîne fixée.

La stratégie identité présente une forte autocorrélation, des ESS faibles et, par conséquent, des estimations moins précises des caractéristiques *a posteriori*.

Les préconditionnements *a priori* et *a posteriori* améliorent fortement l'efficacité et réduisent les erreurs sur la moyenne et les variances marginales.

Sur l'ensemble du plan expérimental, le préconditionnement *a posteriori* associé à

$$\rho = 0.5$$

offre le meilleur compromis parmi les stratégies étudiées.

Il atteint un ESS médian global d'environ

$$530,$$

avec

$$Q_{10} \simeq 482$$

et un minimum proche de

$$477.$$

Cette même combinaison présente également la plus faible erreur moyenne sur les variances marginales,

$$\text{RMSE}_{\text{var}} = 0.01597,$$

ainsi qu'une erreur relative moyenne d'environ

$$3.88\%.$$

La proportion empirique de sites couverts par les intervalles ponctuels est proche de 95 %, avec une largeur comparable à celle des autres stratégies préconditionnées.

Ainsi, le gain du préconditionnement *a posteriori* ne se limite pas à une augmentation de l'ESS. Pour une longueur de chaîne donnée, il permet également d'obtenir des estimations Monte-Carlo plus précises des caractéristiques de la distribution cible.

Dans le cadre du plan expérimental étudié, la stratégie

$$\boxed{\text{préconditionnement a posteriori} + \rho = 0.5}$$

apparaît donc comme le meilleur compromis entre efficacité, précision Monte-Carlo et robustesse.

Le chapitre suivant examine si cette conclusion se maintient dans le modèle géostatistique binaire, où la distribution *a posteriori* n'est plus disponible analytiquement et où la géométrie de la cible doit être approchée localement.

Chapitre 6

Application au modèle géostatistique binaire

Dans le chapitre précédent, les différentes stratégies MALA ont été étudiées dans le cas gaussien, où la loi *a posteriori* du champ latent est connue analytiquement. Ce cadre a permis de valider l'implémentation, d'étudier l'efficacité de l'échantillonnage et d'évaluer la précision de l'estimation de l'incertitude *a posteriori* à partir des variances marginales.

L'objectif est désormais d'étendre cette démarche au modèle géostatistique binaire, pour lequel la loi *a posteriori* du champ latent n'est plus disponible sous une forme analytique directement exploitable. Il s'agit notamment de déterminer si une stratégie MALA peut conserver de bonnes performances lorsque les caractéristiques du modèle varient, c'est-à-dire d'identifier une stratégie à la fois **performante et robuste**.

Dans ce cadre non gaussien, la moyenne et la variance marginale *a posteriori* ne peuvent plus être calculées analytiquement. Elles sont donc estimées directement à partir des échantillons produits par MALA. L'étude de la variance permet ainsi de compléter la reconstruction ponctuelle du champ latent par une quantification de l'incertitude associée.

6.1 Modèle géostatistique binaire

Dans le modèle gaussien, la conjugaison entre la vraisemblance et la loi *a priori* permet d'obtenir explicitement la moyenne et la covariance *a posteriori* du champ latent. Cette propriété disparaît lorsque les observations sont binaires.

On considère désormais un vecteur d'observations

$$y = (y_1, \dots, y_n)^\top, \quad y_i \in \{0, 1\}.$$

Conditionnellement au champ latent w et aux coefficients de régression β , les observations sont supposées indépendantes et suivent une loi de Bernoulli :

$$Y_i \mid w_i, \beta \sim \text{Bernoulli}(p_i), \quad i = 1, \dots, n. \quad (6.1)$$

Le lien logit relie la probabilité p_i au prédicteur linéaire :

$$\text{logit}(p_i) = \log\left(\frac{p_i}{1 - p_i}\right) = x_i^\top \beta + w_i. \quad (6.2)$$

En posant

$$\eta_i = x_i^\top \beta + w_i, \quad (6.3)$$

on obtient

$$p_i = \frac{\exp(\eta_i)}{1 + \exp(\eta_i)}. \quad (6.4)$$

6.1.1 Vraisemblance

La fonction de masse associée à une observation est

$$p(y_i | w_i, \beta) = p_i^{y_i} (1 - p_i)^{1-y_i}. \quad (6.5)$$

Sous l'hypothèse d'indépendance conditionnelle,

$$p(y | w, \beta) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}. \quad (6.6)$$

La log-vraisemblance s'écrit alors

$$\log p(y | w, \beta) = \sum_{i=1}^n [y_i \eta_i - \log(1 + \exp(\eta_i))]. \quad (6.7)$$

6.1.2 Loi *a priori* du champ latent

Comme dans le modèle gaussien, le champ latent est supposé gaussien :

$$w \sim \mathcal{N}(0, Q_0^{-1}), \quad (6.8)$$

où Q_0 désigne la matrice de précision *a priori*.

Avec l'approximation de Vecchia utilisée dans ce travail,

$$Q_0 = \tilde{R}^\top \tilde{R}. \quad (6.9)$$

À une constante indépendante de w près, la log-densité *a priori* s'écrit

$$\log p(w) = -\frac{1}{2} w^\top Q_0 w = -\frac{1}{2} \|\tilde{R}w\|^2. \quad (6.10)$$

6.1.3 Distribution *a posteriori*

D'après la formule de Bayes,

$$p(w | y, \beta) = \frac{p(y | w, \beta) p(w)}{p(y | \beta)}. \quad (6.11)$$

Le terme $p(y | \beta)$ étant indépendant de w , la distribution cible s'écrit

$$p(w | y, \beta) \propto p(y | w, \beta) p(w). \quad (6.12)$$

En combinant la vraisemblance de Bernoulli et la loi *a priori* gaussienne,

$$p(w | y, \beta) \propto \left[\prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i} \right] \exp \left(-\frac{1}{2} w^\top Q_0 w \right). \quad (6.13)$$

Contrairement au cas gaussien, cette expression ne correspond plus à une loi gaussienne dont les paramètres peuvent être calculés explicitement. La moyenne et la covariance *a posteriori* du champ latent doivent donc être estimées numériquement.

Pour MALA, la constante de normalisation n'est toutefois pas nécessaire. Il suffit de pouvoir évaluer la log-densité cible et son gradient.

À une constante additive près,

$$\log p(w \mid y, \beta) = \sum_{i=1}^n [y_i \eta_i - \log(1 + \exp(\eta_i))] - \frac{1}{2} w^\top Q_0 w. \quad (6.14)$$

6.1.4 Gradient et Hessienne de la log-postérieure

L'algorithme MALA utilise le gradient de la log-postérieure afin d'orienter les propositions. Pour une observation,

$$\frac{\partial}{\partial w_i} [y_i \eta_i - \log(1 + \exp(\eta_i))] = y_i - p_i. \quad (6.15)$$

Par ailleurs,

$$\nabla_w \left(-\frac{1}{2} w^\top Q_0 w \right) = -Q_0 w. \quad (6.16)$$

Le gradient de la log-postérieure est donc

$$\boxed{\nabla_w \log p(w \mid y, \beta) = y - p - Q_0 w} \quad (6.17)$$

où

$$p = (p_1, \dots, p_n)^\top.$$

Avec $Q_0 = \tilde{R}^\top \tilde{R}$,

$$\nabla_w \log p(w \mid y, \beta) = y - p - \tilde{R}^\top \tilde{R} w. \quad (6.18)$$

Pour caractériser la courbure locale de la distribution cible, on définit

$$D(w) = \text{diag}(p_1(1 - p_1), \dots, p_n(1 - p_n)). \quad (6.19)$$

La Hessienne de la log-postérieure est alors

$$\boxed{\nabla_w^2 \log p(w \mid y, \beta) = -[Q_0 + D(w)]}. \quad (6.20)$$

On introduit ainsi la matrice de courbure locale

$$\boxed{Q(w) = -\nabla_w^2 \log p(w \mid y, \beta) = Q_0 + D(w)}. \quad (6.21)$$

Cette matrice joue le rôle d'une précision dans une approximation gaussienne locale de la loi *a posteriori*. Elle ne constitue toutefois pas une matrice de précision postérieure exacte, puisque sa valeur dépend du champ latent w .

6.1.5 Du cas gaussien au cas binaire

Dans le modèle gaussien, la Hessienne négative de la log-postérieure est constante et correspond exactement à

$$Q_{\text{post}} = Q_0 + \tau^{-2} I_n. \quad (6.22)$$

La géométrie de la distribution cible est donc connue analytiquement.

Dans le modèle binaire,

$$-\nabla_w^2 \log p(w \mid y, \beta) = Q_0 + D(w), \quad (6.23)$$

et $D(w)$ dépend de w à travers les probabilités p_i . La courbure de la distribution cible varie donc dans l'espace des états. Il n'existe plus de matrice de précision *a posteriori* constante analogue à celle du modèle gaussien.

Pour construire un préconditionnement fixe incorporant l'information apportée par les observations, la courbure est évaluée au mode de la distribution *a posteriori*, ou MAP.

6.1.6 Calcul du MAP (Maximum *A Posteriori*)

Le MAP est défini par

$$w_{\text{MAP}} = \arg \max_w \log p(w \mid y, \beta). \quad (6.24)$$

Au MAP,

$$\nabla_w \log p(w_{\text{MAP}} \mid y, \beta) = 0, \quad (6.25)$$

soit

$$y - p_{\text{MAP}} - Q_0 w_{\text{MAP}} = 0. \quad (6.26)$$

Le MAP est calculé numériquement par une méthode de Newton. À l'itération k ,

$$w^{(k+1)} = w^{(k)} + \left[Q_0 + D(w^{(k)}) \right]^{-1} \left[y - p^{(k)} - Q_0 w^{(k)} \right]. \quad (6.27)$$

Les itérations sont poursuivies jusqu'à convergence.

6.1.7 Stratégies de préconditionnement

Une fois le MAP obtenu, on définit

$$D_{\text{MAP}} = \text{diag} (p_{1,\text{MAP}}(1 - p_{1,\text{MAP}}), \dots, p_{n,\text{MAP}}(1 - p_{n,\text{MAP}})), \quad (6.28)$$

puis

$$\boxed{Q_{\text{MAP}} = Q_0 + D_{\text{MAP}}.} \quad (6.29)$$

La matrice Q_{MAP} correspond à la courbure négative de la log-postérieure évaluée au mode. Elle définit donc une approximation locale de la géométrie de la distribution cible, mais ne doit pas être interprétée comme une précision postérieure exacte.

Deux stratégies sont comparées :

- le préconditionnement *a priori*, construit à partir de Q_0 et correspondant au préconditionneur Q_0^{-1} ;
- le préconditionnement au MAP, construit à partir de Q_{MAP} et correspondant au préconditionneur Q_{MAP}^{-1} .

Le premier utilise uniquement la structure spatiale imposée par la loi *a priori*, tandis que le second incorpore également l'information apportée par les observations binaires à travers la courbure de la log-vraisemblance évaluée au MAP.

6.2 Protocole expérimental

6.2.1 Génération des données

Les expériences sont réalisées sur un domaine spatial bidimensionnel contenant

$$n = 10\,000$$

sites.

Les positions spatiales sont simulées sur le domaine. La matrice de régression est construite sous la forme

$$X = \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}, \quad x_i \sim \mathcal{N}(0, 1). \quad (6.30)$$

Le vecteur des coefficients est

$$\beta = \begin{pmatrix} \beta_0 \\ 0.01 \end{pmatrix}. \quad (6.31)$$

Le coefficient $\beta_1 = 0.01$ est maintenu fixé dans toutes les expériences. Seul l'intercept β_0 varie dans le plan factoriel afin d'étudier l'influence du niveau moyen du prédicteur sur les observations binaires et sur l'efficacité de l'échantillonnage.

Le champ latent est simulé à partir d'une covariance de Matérn caractérisée notamment par sa variance marginale σ^2 , sa régularité ν et son échelle de dépendance spatiale.

Afin de distinguer le paramètre de régularité ν du paramètre contrôlant l'échelle spatiale, le plan expérimental est exprimé à partir de la quantité

$$\ell^* = \frac{\ell}{\sqrt{\nu}}. \quad (6.32)$$

Le champ latent est simulé selon

$$w = \tilde{R}^{-1}z, \quad z \sim \mathcal{N}(0, I_n). \quad (6.33)$$

Les probabilités d'observation sont ensuite données par

$$p_i = \text{logit}^{-1}(\beta_0 + 0.01x_i + w_i), \quad (6.34)$$

puis les observations sont simulées selon

$$Y_i \sim \text{Bernoulli}(p_i). \quad (6.35)$$

6.2.2 Initialisation et réglage des chaînes

Pour chaque jeu de données, le MAP est calculé avant l'exécution de la chaîne et utilisé comme point initial :

$$w^{(0)} = w_{\text{MAP}}. \quad (6.36)$$

Chaque chaîne comporte 10 000 itérations, dont les 2 000 premières constituent la phase de *burn-in*. Pendant cette phase, le pas est adapté par la procédure de Robbins–Monro afin de viser un taux d'acceptation de

$$\alpha^* = 0.574. \quad (6.37)$$

Après le *burn-in*, le pas est maintenu constant pendant les 8 000 itérations restantes.

La persistance du momentum est contrôlée par le paramètre ρ .

6.2.3 Plan factoriel

Le plan expérimental vise à étudier conjointement l'influence de la structure du champ latent, du niveau moyen des probabilités d'observation, de la persistance du momentum et du préconditionnement.

TABLE 6.1 – Paramètres considérés dans l'expérience factorielle du modèle binaire.

Paramètre	Valeurs testées
Variance marginale σ^2	0.5, 1, 2
Régularité ν	0.5, 1.5
Échelle spatiale $\ell^* = \ell/\sqrt{\nu}$	0.05, 0.2, 0.5
Intercept β_0	-1, 0, 1
Coefficient β_1	0.01 (fixé)
Persistance ρ	0, 0.5, 0.9
Préconditionnement	a priori, au MAP
Nombre de répétitions	5

Le coefficient β_1 étant fixé, il n'intervient pas dans le nombre de configurations. Le plan comporte ainsi

$$3 \times 2 \times 3 \times 3 \times 3 \times 2 \times 5 = 1620 \quad (6.38)$$

chaînes MCMC.

La variance marginale σ^2 contrôle l'amplitude des fluctuations du champ latent. Le paramètre ν contrôle sa régularité, tandis que ℓ^* caractérise l'échelle spatiale utilisée dans le plan expérimental.

Il convient de distinguer σ^2 du paramètre τ^2 étudié dans le cas gaussien. Dans le chapitre précédent, τ^2 représentait la variance du bruit d'observation. Dans le modèle binaire, ce bruit gaussien n'existe plus : σ^2 désigne ici la variance marginale du champ latent w .

L'intercept β_0 agit sur le niveau moyen du prédicteur

$$\eta_i = \beta_0 + 0.01x_i + w_i. \quad (6.39)$$

Il modifie ainsi la proportion attendue d'observations égales à 1. Il agit également sur les quantités $p_i(1 - p_i)$ et peut donc modifier la courbure locale de la log-vraisemblance et, par conséquent, la géométrie de la distribution *a posteriori*.

Enfin, ρ est un paramètre algorithmique contrôlant la persistance du momentum.

Pour une même combinaison de paramètres et une même graine, les données simulées sont identiques pour les différentes valeurs de ρ et pour les deux préconditionnements. Les méthodes sont ainsi comparées sur une même réalisation du problème.

Les cinq graines correspondent à cinq réalisations simulées distinctes pour chaque combinaison des paramètres du modèle. Elles permettent d'évaluer la variabilité des performances liée à la génération des positions, du champ latent et des observations. Elles ne sont pas considérées comme des paramètres scientifiques du modèle.

6.2.4 Critères de comparaison

Pour chaque chaîne, l'ESS moyen, médian, minimal et maximal sont calculés.

Compte tenu de la dimension du champ latent, la moyenne et la variance *a posteriori* sont mises à jour en ligne sur l'ensemble des $n = 10\,000$ composantes, afin de ne pas conserver tous les états successifs de la chaîne.

Pour chaque site i , la moyenne postérieure est estimée par

$$\hat{\mu}_i = \frac{1}{N} \sum_{t=1}^N w_i^{(t)}, \quad (6.40)$$

où $N = 8\,000$ désigne le nombre d'itérations conservées après le *burn-in*.

La variance marginale postérieure est estimée par

$$\hat{v}_i = \widehat{\text{Var}}(w_i | y) = \frac{1}{N-1} \sum_{t=1}^N \left(w_i^{(t)} - \hat{\mu}_i \right)^2. \quad (6.41)$$

Dans l'implémentation, ces deux quantités sont calculées en ligne afin de limiter le coût mémoire. Il n'est donc pas nécessaire de stocker une matrice de taille $8\,000 \times 10\,000$ pour chaque chaîne.

Le calcul de l'ESS nécessite en revanche de conserver les trajectoires postérieures des composantes considérées. Afin de limiter le coût mémoire, notamment lors de l'exécution parallèle des chaînes, l'ESS est évalué sur un sous-ensemble de 100 composantes régulièrement réparties parmi les indices du champ latent.

Les indicateurs ESS_{moy} , ESS_{med} , ESS_{min} et ESS_{max} résument les ESS obtenus sur ce sous-ensemble.

Ce choix concerne uniquement le diagnostic d'autocorrélation : la chaîne MCMC reste définie sur les 10 000 composantes du champ latent, et les estimations de la moyenne et de la variance *a posteriori* sont calculées sur l'ensemble du champ.

L'ESS médian est retenu comme critère principal d'efficacité, car il fournit une mesure synthétique moins sensible aux valeurs extrêmes. L'ESS minimal complète cette information en renseignant sur les composantes les plus difficiles à échantillonner.

Le taux d'acceptation et le pas final permettent d'évaluer le comportement de l'algorithme. Le temps d'exécution est également enregistré afin de distinguer l'efficacité statistique de l'efficacité computationnelle.

La qualité de reconstruction du champ latent est résumée par

$$\text{RMSE}_w = \sqrt{\frac{1}{n} \sum_{i=1}^n (w_i - \hat{\mu}_i)^2}. \quad (6.42)$$

Contrairement à la RMSE utilisée pour la validation analytique du modèle gaussien, cette quantité mesure ici l'écart entre le champ latent simulé et la moyenne postérieure estimée.

Enfin, aucune covariance postérieure exacte n'est disponible dans le modèle binaire. L'analyse de l'incertitude repose donc sur les variances marginales estimées par MCMC et sur leur représentation spatiale.

6.3 Reconstruction du champ latent et incertitude postérieure

Trois configurations sont retenues afin d'illustrer des situations contrastées. Elles diffèrent par σ^2 , ν , ℓ^* et β_0 , tandis que

$$\beta_1 = 0.01$$

reste fixé dans l'ensemble des expériences.

Pour chaque configuration, quatre quantités sont représentées : les observations binaires, le champ latent simulé, la moyenne *a posteriori* estimée par MCMC et la variance marginale *a posteriori* estimée.

Les observations ne prennent que les valeurs 0 et 1 et ne permettent donc pas d'observer directement l'amplitude du champ latent. La comparaison entre le champ simulé et la moyenne

postérieure permet d'évaluer qualitativement la reconstruction spatiale. La carte de variance fournit une information complémentaire sur l'incertitude associée à cette reconstruction.




FIGURE 6.1 – Observations binaires, champ latent simulé, moyenne *a posteriori* et variance marginale *a posteriori* estimées par MCMC pour trois configurations du modèle géostatistique binaire.

La Figure 6.1 illustre la difficulté du problème inverse. Les observations binaires ne fournissent qu'une information indirecte sur l'amplitude du champ latent. Malgré cette perte d'information, les moyennes postérieures reproduisent les principales structures spatiales des champs simulés.

Dans la première configuration, ($\sigma^2 = 0.5, \nu = 0.5, \ell^* = 0.05, \beta_0 = 0$), la faible régularité et la courte échelle spatiale produisent des variations relativement locales du champ latent. La moyenne postérieure retrouve les principales structures, mais atténue certaines fluctuations de petite échelle.

La carte de variance montre également une incertitude non négligeable et spatialement hétérogène. Les valeurs observées sur cette réalisation sont approximativement comprises entre 0.11 et 0.29. La reconstruction donnée par la moyenne doit donc être accompagnée de cette information sur la dispersion postérieure.

Dans la deuxième configuration, ($\sigma^2 = 1, \nu = 1.5, \ell^* = 0.2, \beta_0 = 0$), l'augmentation de la régularité et de l'échelle spatiale produit des structures plus étendues. Ces structures sont nettement visibles dans le champ latent et sont bien reproduites par la moyenne postérieure.

La variance postérieure apparaît relativement faible sur une grande partie du domaine, tandis que certaines régions présentent des niveaux d'incertitude plus élevés, notamment dans plusieurs zones périphériques. Cette observation reste descriptive : les figures seules ne permettent pas d'attribuer ces variations à un mécanisme particulier.

Dans la troisième configuration, ($\sigma^2 = 2, \nu = 1.5, \ell^* = 0.5, \beta_0 = 1$), la variance marginale et l'échelle spatiale sont plus élevées et l'intercept est positif. La proportion observée de 1 atteint environ 0.765, contre 0.497 et 0.555 dans les deux premières configurations.

Cette augmentation est cohérente avec la valeur $\beta_0 = 1$, qui décale positivement le prédicteur linéaire. Les autres paramètres variant également, cette différence ne peut toutefois pas être attribuée uniquement à β_0 .

La structure à grande échelle du champ latent est ici particulièrement visible et la moyenne postérieure en reproduit correctement l'organisation générale. La carte de variance montre à nouveau une incertitude plus faible dans certaines régions et plus élevée dans d'autres, sans qu'une cause unique puisse être déduite de cette seule représentation.

Ces comparaisons restent illustratives. Puisque plusieurs paramètres varient simultanément entre les trois configurations, elles ne permettent pas d'isoler graphiquement l'effet propre de σ^2 , de ν , de ℓ^* ou de β_0 .

6.4 Analyse de l'incertitude postérieure

L'analyse de la moyenne postérieure ne suffit pas à caractériser complètement la reconstruction du champ latent. Deux composantes présentant des moyennes postérieures comparables peuvent en effet être associées à des niveaux de dispersion différents.

Pour chaque site i , la quantité

$$\widehat{\text{Var}}(w_i \mid y)$$

mesure la dispersion des valeurs de w_i visitées par la chaîne après le *burn-in*. Une valeur faible correspond à une distribution postérieure plus concentrée autour de sa moyenne, tandis qu'une valeur plus élevée traduit une incertitude postérieure plus importante.

Il est essentiel de distinguer cette quantité de l'erreur de reconstruction. La variance postérieure n'est pas définie par

$$(w_i - \hat{\mu}_i)^2.$$

Une région présentant une variance élevée n'est donc pas nécessairement une région dans laquelle la moyenne postérieure est éloignée du champ simulé.

Cette distinction est particulièrement importante dans le cas binaire. Une observation individuelle ne contient qu'une information de type 0/1 et ne détermine pas directement l'amplitude de w_i . L'inférence sur le champ latent repose simultanément sur la vraisemblance Bernoulli-logistique et sur la dépendance spatiale imposée par le prior.

La courbure locale de la vraisemblance intervient à travers

$$D(w) = \text{diag}(p_i(1 - p_i)). \quad (6.43)$$

La courbure négative de la log-postérieure est alors

$$-\nabla_w^2 \log p(w \mid y, \beta) = Q_0 + D(w). \quad (6.44)$$

Cette expression permet de comprendre qualitativement comment l'information apportée par les observations se combine avec la structure spatiale du prior. Elle ne fournit toutefois pas directement la covariance marginale *a posteriori*.

En particulier,

$$Q_{\text{MAP}}^{-1}$$

constitue une approximation gaussienne locale de la covariance autour du mode et non la covariance exacte de $w \mid y$.

Dans le cas gaussien, la disponibilité de la covariance analytique permettait de calculer une erreur entre variance MCMC et variance exacte. Une telle comparaison n'est plus disponible ici.

Les cartes présentées doivent donc être interprétées comme des estimations MCMC de l'incertitude marginale *a posteriori*, et non comme une validation par rapport à une référence analytique.

Enfin, les échelles graphiques des trois cartes de variance ne sont pas identiques. Une même couleur ne correspond donc pas nécessairement à la même valeur de variance d'une configuration à l'autre. Les comparaisons entre configurations doivent s'appuyer sur les valeurs numériques des échelles.

L'ajout de cette analyse permet ainsi de compléter la reconstruction du champ latent : la moyenne postérieure fournit une estimation de sa valeur centrale, tandis que la variance marginale renseigne sur l'incertitude associée.

6.5 Analyse de l'efficacité de l'échantillonnage

L'analyse précédente décrit les quantités estimées à partir des chaînes. Il reste maintenant à étudier l'efficacité avec laquelle les différentes stratégies MALA explorent la distribution *a posteriori*.

Comme dans le cas gaussien, l'objectif n'est pas seulement d'obtenir une reconstruction satisfaisante du champ latent, mais d'identifier une stratégie d'échantillonnage efficace et robuste lorsque les paramètres du modèle varient.

6.5.1 Comparaison globale des préconditionnements

Le Tableau 6.2 présente les performances moyennes obtenues sur l'ensemble du plan expérimental.

TABLE 6.2 – Performances moyennes des deux stratégies de préconditionnement.

Précond.	ESS méd.	ESS min.	Pas	Accept.	RMSE champ	Temps (s)
A priori	75.88	40.64	0.102	0.570	0.327	337.24
Au MAP	164.44	122.84	0.357	0.568	0.321	335.91

Sur l'ensemble du plan expérimental, le préconditionnement au MAP présente une efficacité statistique nettement supérieure. L'ESS médian moyen passe d'environ 76 avec le préconditionnement *a priori* à 164 avec le préconditionnement au MAP.

L'ESS minimal moyen augmente également fortement, passant d'environ 41 à 123. Le gain ne concerne donc pas uniquement les composantes les plus faciles à échantillonner : les composantes les plus fortement autocorrélées bénéficient également du préconditionnement au MAP.

Les taux d'acceptation restent très proches pour les deux stratégies et sont voisins de la cible 0.574. En revanche, le préconditionnement au MAP permet d'utiliser un pas moyen d'environ 0.357, contre seulement 0.102 avec le préconditionnement *a priori*.

Ainsi, pour un taux d'acceptation comparable, la prise en compte de la courbure de la log-postérieure au MAP autorise des déplacements sensiblement plus importants dans l'espace des états.

La RMSE de reconstruction reste en revanche très proche entre les deux stratégies :

$$0.327 \quad \text{contre} \quad 0.321.$$

Ce résultat est cohérent avec le fait que les deux algorithmes ciblent la même distribution *a posteriori*. Le principal gain du préconditionnement au MAP concerne donc l'efficacité avec laquelle cette distribution est explorée pour une longueur de chaîne donnée, plutôt qu'une modification systématique de la reconstruction obtenue.

Enfin, les temps moyens d'exécution sont pratiquement identiques. Le gain d'ESS obtenu avec le préconditionnement au MAP ne s'accompagne donc pas, dans ces expériences, d'une augmentation du coût moyen de calcul.

6.5.2 Performance et robustesse des stratégies

La Figure 6.2 présente la distribution de l'ESS médian selon la persistance du momentum ρ et le préconditionnement.




FIGURE 6.2 – Distribution de l'ESS médian selon la persistance du momentum ρ et la stratégie de préconditionnement.

L'objectif n'est pas uniquement d'identifier la stratégie pouvant atteindre le plus grand ESS dans une configuration particulière, mais de rechercher une stratégie conservant de bonnes performances lorsque les paramètres du modèle changent.

Le premier décile Q_{10} constitue ici un indicateur de robustesse : il décrit le niveau d'ESS encore atteint dans la partie la moins favorable de la distribution des performances.

Le Tableau 6.3 résume la distribution de l'ESS médian pour chacune des six combinaisons entre préconditionnement et persistance du momentum.

TABLE 6.3 – Résumé de l’ESS médian selon la stratégie MALA dans le modèle binaire.

Stratégie	ρ	Moyenne	Médiane	Écart-type	Q_{10}	Minimum
A priori	0	51.93	40.76	34.25	18.55	12.11
A priori	0.5	74.61	57.25	54.29	23.87	13.67
A priori	0.9	101.09	80.09	69.44	32.62	14.21
Au MAP	0	151.90	151.79	3.70	147.27	139.98
Au MAP	0.5	213.38	215.48	17.36	191.02	152.22
Au MAP	0.9	128.05	125.65	32.91	86.31	60.03

Ces résultats mettent en évidence deux comportements très différents.

Avec le préconditionnement *a priori*, l’augmentation de la persistance du momentum améliore l’ESS moyen, mais les distributions restent très dispersées. Pour $\rho = 0.9$, l’ESS médian global atteint environ 80, mais son premier décile reste proche de 33 et certaines chaînes présentent un ESS médian inférieur à 15.

Le préconditionnement au MAP produit au contraire des performances beaucoup plus homogènes. Avec $\rho = 0$, l’ESS médian global est déjà d’environ 152 avec un écart-type inférieur à 4.

La meilleure combinaison entre niveau de performance et robustesse est cependant obtenue pour

$$\rho = 0.5.$$

Dans ce cas, l’ESS médian global atteint environ

$$215.5,$$

tandis que le premier décile reste supérieur à

$$191.$$

Ainsi, environ 90 % des chaînes de cette stratégie présentent un ESS médian supérieur à 191 dans le plan expérimental considéré.

La dispersion reste également limitée, avec un écart-type d’environ 17.4. Le préconditionnement au MAP associé à $\rho = 0.5$ combine donc une efficacité élevée et une faible sensibilité aux paramètres du modèle.

Lorsque $\rho = 0.9$, les performances du préconditionnement au MAP diminuent et deviennent plus variables. Une persistance trop importante ne semble donc pas favorable à cette stratégie.

Ces résultats conduisent à retenir le préconditionnement au MAP associé à $\rho = 0.5$ comme le meilleur compromis entre performance et robustesse parmi les stratégies étudiées.

6.5.3 Influence des paramètres du modèle

Afin de compléter l’analyse globale de robustesse, un modèle linéaire est utilisé pour étudier l’influence des paramètres du modèle sur l’ESS médian.

Le facteur *seed* est introduit comme facteur de contrôle. Il permet de tenir compte de la variabilité entre les cinq réalisations, mais n’est pas interprété comme un facteur scientifique.

Le modèle ajusté est

$$\begin{aligned} \text{ESS}_{\text{med}} \sim & \text{seed} + \sigma^2 \times \text{prconditionnement} + \nu \times \text{prconditionnement} \\ & + \ell^* \times \text{prconditionnement} + \beta_0 \times \text{prconditionnement} + \rho \times \text{prconditionnement}. \end{aligned} \quad (6.45)$$

La Figure 6.3 présente la sortie complète du modèle.

```
Call:
lm(formula = ess_median ~ factor(seed) + factor(sigma2) * factor(conditioning) +
    factor(nu) * factor(conditioning) + factor(range) * factor(conditioning) +
    factor(beta0) * factor(conditioning) + factor(rho) * factor(conditioning),
    data = experiment_results)

Residuals:
    Min       1Q   Median       3Q      Max
-66.13 -12.00  -1.12   10.47  170.62

Coefficients:
                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                   130.8954     2.7028   48.430 < 2e-16 ***
factor(seed)2                   -0.9400     1.7446   -0.539  0.59010
factor(seed)3                   -0.1654     1.7446   -0.095  0.92448
factor(seed)4                    0.8621     1.7446    0.494  0.62129
factor(seed)5                    1.8440     1.7446    1.057  0.29070
factor(sigma2)1                 -34.6631     1.9112  -18.137 < 2e-16 ***
factor(sigma2)2                 -56.3858     1.9112  -29.504 < 2e-16 ***
factor(conditioning)2           18.9844     3.4893    5.441 6.13e-08 ***
factor(nu)1.5                   23.6428     1.5605   15.151 < 2e-16 ***
factor(range)0.2                -81.1678     1.9112  -42.471 < 2e-16 ***
factor(range)0.5               -95.6019     1.9112  -50.023 < 2e-16 ***
factor(beta0)0                  -5.7601     1.9112   -3.014  0.00262 **
factor(beta0)1                   0.2532     1.9112    0.132  0.89461
factor(rho)0.5                  22.6813     1.9112   11.868 < 2e-16 ***
factor(rho)0.9                  49.1607     1.9112   25.723 < 2e-16 ***
factor(sigma2)1:factor(conditioning)2 36.0130     2.7028   13.324 < 2e-16 ***
factor(sigma2)2:factor(conditioning)2 56.8764     2.7028   21.044 < 2e-16 ***
factor(conditioning)2:factor(nu)1.5 -23.6633     2.2068  -10.723 < 2e-16 ***
factor(conditioning)2:factor(range)0.2 83.9390     2.7028   31.056 < 2e-16 ***
factor(conditioning)2:factor(range)0.5 98.7329     2.7028   36.530 < 2e-16 ***
factor(conditioning)2:factor(beta0)0   5.3456     2.7028    1.978  0.04812 *
factor(conditioning)2:factor(beta0)1  -2.4601     2.7028   -0.910  0.36286
factor(conditioning)2:factor(rho)0.5  38.8045     2.7028   14.357 < 2e-16 ***
factor(conditioning)2:factor(rho)0.9 -73.0091     2.7028  -27.013 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 22.21 on 1596 degrees of freedom
Multiple R-squared:  0.8927,    Adjusted R-squared:  0.8911
F-statistic: 577.1 on 23 and 1596 DF, p-value: < 2.2e-16
```

FIGURE 6.3 – Résultats du modèle linéaire expliquant les variations de l’ESS médian dans le modèle binaire.

Le modèle est globalement hautement significatif,

$$p < 2.2 \times 10^{-16},$$

et explique près de 89.3 % de la variabilité de l’ESS médian :

$$R^2 = 0.8927, \quad R_{\text{ajust}}^2 = 0.8911.$$

Les coefficients associés aux différentes graines ne sont pas significatifs, ce qui indique qu’aucun effet systématique important des réalisations n’est mis en évidence.

Les interactions avec le préconditionnement montrent que l’effet de plusieurs paramètres du modèle dépend fortement de la stratégie MALA utilisée. En présence de ces interactions, les effets principaux doivent être interprétés relativement aux modalités de référence et non comme des effets moyens sur l’ensemble du plan expérimental.

TABLE 6.4 – Effets estimés des principaux paramètres sur l’ESS médian selon le préconditionnement.

Variation	A priori	Au MAP
$\sigma^2 : 0.5 \rightarrow 1$	-34.66	+1.35
$\sigma^2 : 0.5 \rightarrow 2$	-56.39	+0.49
$\nu : 0.5 \rightarrow 1.5$	+23.64	-0.02
$\ell^* : 0.05 \rightarrow 0.2$	-81.17	+2.77
$\ell^* : 0.05 \rightarrow 0.5$	-95.60	+3.13
$\rho : 0 \rightarrow 0.5$	+22.68	+61.49
$\rho : 0 \rightarrow 0.9$	+49.16	-23.85

Les interactions mettent en évidence une différence importante de sensibilité entre les deux stratégies.

Avec le préconditionnement *a priori*, l’augmentation de la variance marginale du champ latent dégrade fortement l’efficacité. Le passage de $\sigma^2 = 0.5$ à $\sigma^2 = 2$ est associé à une diminution estimée de

$$-56.39$$

de l’ESS médian.

Avec le préconditionnement au MAP, l’interaction correspondante vaut +56.88, de sorte que l’effet total devient

$$-56.39 + 56.88 \simeq 0.49.$$

L’ESS devient donc pratiquement insensible à cette variation de σ^2 dans le modèle ajusté lorsque le préconditionnement au MAP est utilisé.

Un comportement analogue est observé pour l’échelle spatiale. Avec le préconditionnement *a priori*, le passage de $\ell^* = 0.05$ à $\ell^* = 0.5$ est associé à une diminution estimée d’environ

$$95.6$$

de l’ESS médian.

Avec le préconditionnement au MAP, l’effet total devient

$$-95.60 + 98.73 \simeq 3.13.$$

La sensibilité de l’ESS à l’échelle spatiale est donc fortement atténuée.

Pour la régularité, le passage de $\nu = 0.5$ à $\nu = 1.5$ est associé à une augmentation estimée de 23.64 avec le préconditionnement *a priori*. L’interaction correspondante avec le préconditionnement au MAP vaut -23.66, d’où un effet total pratiquement nul :

$$23.64 - 23.66 \simeq -0.02.$$

Ces résultats suggèrent que le préconditionnement au MAP compense une part importante de l’effet des changements de géométrie induits par les paramètres du modèle sur l’efficacité de l’échantillonnage.

La persistance du momentum présente toutefois un comportement différent.

Avec le préconditionnement au MAP, le passage de $\rho = 0$ à $\rho = 0.5$ produit un effet total estimé de

$$22.68 + 38.80 \simeq 61.49,$$

alors que pour $\rho = 0.9$ l’effet devient

$$49.16 - 73.01 \simeq -23.85.$$

Une persistance intermédiaire apparaît ainsi nettement plus favorable au préconditionnement au MAP qu’une persistance élevée.

Enfin, l’effet de β_0 reste comparativement faible. Pour $\beta_0 = 0$, un effet de faible amplitude mais statistiquement significatif est observé, tandis que pour $\beta_0 = 1$ ni l’effet principal ni l’interaction avec le préconditionnement au MAP ne sont significatifs au seuil de 5 %.

6.6 Discussion des résultats

L’étude du modèle binaire confirme le rôle déterminant du préconditionnement dans l’efficacité de l’échantillonnage.

Le préconditionnement *a priori* exploite uniquement la structure spatiale du champ latent. Ses performances peuvent être élevées dans certaines configurations, mais restent fortement dépendantes des paramètres du modèle.

Le préconditionnement au MAP incorpore également la courbure locale de la vraisemblance Bernoulli-logistique. Bien qu’il ne décrive la géométrie de la postérieure qu’au voisinage du mode, il conduit à des performances beaucoup plus homogènes dans le plan expérimental.

Cette robustesse apparaît à la fois dans les distributions d’ESS et dans le modèle linéaire : les effets de σ^2 , de ν et de ℓ^* sur l’efficacité sont fortement atténués lorsque le préconditionnement au MAP est utilisé.

La persistance du momentum interagit cependant avec le choix du préconditionnement. Une valeur intermédiaire, $\rho = 0.5$, améliore fortement les performances du préconditionnement au MAP, tandis qu’une persistance plus élevée, $\rho = 0.9$, devient défavorable.

L’analyse de l’incertitude complète ces diagnostics. La moyenne *a posteriori* décrit la valeur centrale estimée du champ latent, tandis que la variance marginale caractérise la dispersion résiduelle autour de cette estimation. Contrairement au modèle gaussien, aucune référence analytique exacte n’est disponible pour valider quantitativement ces variances.

Dans le domaine expérimental étudié, la combinaison du préconditionnement au MAP et de $\rho = 0.5$ fournit ainsi le meilleur compromis entre niveau d’ESS, stabilité des performances et coût de calcul.

Conclusion

L’application au modèle géostatistique binaire a permis d’étudier MALA dans un premier cadre non gaussien, où la distribution *a posteriori* du champ latent n’est plus disponible analytiquement.

La courbure de la log-postérieure dépend alors du champ latent à travers les quantités $p_i(1 - p_i)$. L’évaluation de cette courbure au MAP permet de construire un préconditionnement fixe incorporant à la fois la structure spatiale du prior et l’information apportée par les observations.

Sur l’ensemble du plan expérimental, ce préconditionnement améliore fortement l’efficacité de l’échantillonnage. L’ESS médian moyen passe d’environ

76

avec le préconditionnement *a priori* à environ

164

avec le préconditionnement au MAP, tandis que les temps moyens d’exécution restent comparables.

L'analyse de robustesse met plus particulièrement en évidence la combinaison

$$\boxed{Q_{\text{MAP}} + \rho = 0.5}$$

pour laquelle l'ESS médian global atteint environ

$$215,$$

avec

$$Q_{10} \simeq 191.$$

Le modèle linéaire confirme que cette stratégie est beaucoup moins sensible aux variations de σ^2 , de ν et de l'échelle spatiale que le préconditionnement fondé uniquement sur le prior.

L'étude a également été étendue à l'incertitude postérieure. Les variances marginales estimées par MCMC permettent de compléter la reconstruction ponctuelle du champ latent par une mesure locale de sa dispersion. En l'absence de covariance postérieure analytique, elles ne peuvent cependant pas être validées de la même manière que dans le modèle gaussien.

Ainsi, dans le domaine expérimental considéré, le préconditionnement fondé sur la courbure au MAP associé à une persistance intermédiaire du momentum constitue la stratégie la plus performante et la plus robuste parmi celles étudiées.

Le chapitre suivant examine si cette conclusion se maintient lorsque la loi d'observation est à nouveau modifiée. Un modèle géostatistique de Poisson est considéré afin d'étudier le comportement de la même stratégie pour des données de comptage et une géométrie postérieure différente de celle du modèle Bernoulli-logistique.

Chapitre 7

Application au modèle géostatistique de Poisson

Dans le chapitre précédent, l'étude a été menée dans le modèle géostatistique binaire, où la loi *a posteriori* du champ latent n'est plus disponible analytiquement. Le préconditionnement construit à partir de la courbure locale au MAP s'est révélé particulièrement efficace et robuste.

L'objectif est désormais d'étudier si cette conclusion se maintient lorsque la loi d'observation est modifiée. On considère pour cela un modèle géostatistique de Poisson avec lien logarithmique, adapté à des données de comptage.

Comme dans le modèle binaire, la moyenne et la variance marginale *a posteriori* ne sont pas disponibles analytiquement. Elles sont donc estimées directement à partir des échantillons produits par MALA.

Le modèle de Poisson présente cependant une géométrie locale différente. Dans le modèle binaire, la courbure de la vraisemblance est gouvernée par $p_i(1 - p_i)$, quantité bornée par $1/4$. Dans le modèle de Poisson, elle dépend directement de l'intensité λ_i et peut donc varier sur une échelle beaucoup plus large.

Cette différence permet de tester si les conclusions obtenues dans le modèle binaire se maintiennent dans une seconde situation non gaussienne.

7.1 Modèle géostatistique de Poisson

On considère un vecteur d'observations de comptage

$$y = (y_1, \dots, y_n)^\top, \quad y_i \in \mathbb{N}.$$

Conditionnellement au champ latent w et aux coefficients de régression β , les observations sont supposées indépendantes et suivent une loi de Poisson :

$$Y_i \mid w_i, \beta \sim \text{Poisson}(\lambda_i), \quad i = 1, \dots, n. \quad (7.1)$$

Le lien logarithmique relie l'intensité λ_i au prédicteur linéaire :

$$\log(\lambda_i) = x_i^\top \beta + w_i. \quad (7.2)$$

En posant

$$\eta_i = x_i^\top \beta + w_i, \quad (7.3)$$

on obtient

$$\lambda_i = \exp(\eta_i). \quad (7.4)$$

7.1.1 Vraisemblance

La fonction de masse associée à une observation est

$$p(y_i | w_i, \beta) = \frac{\lambda_i^{y_i} \exp(-\lambda_i)}{y_i!}. \quad (7.5)$$

Sous l'hypothèse d'indépendance conditionnelle,

$$p(y | w, \beta) = \prod_{i=1}^n \frac{\lambda_i^{y_i} \exp(-\lambda_i)}{y_i!}. \quad (7.6)$$

La log-vraisemblance s'écrit alors

$$\log p(y | w, \beta) = \sum_{i=1}^n [y_i \eta_i - \exp(\eta_i) - \log(y_i!)] . \quad (7.7)$$

Pour l'échantillonnage du champ latent, le terme $\log(y_i!)$ ne dépend pas de w et peut donc être absorbé dans une constante. On écrit ainsi

$$\log p(y | w, \beta) = \sum_{i=1}^n [y_i \eta_i - \exp(\eta_i)] + C. \quad (7.8)$$

7.1.2 Loi *a priori* du champ latent

Comme dans les modèles précédents, le champ latent est supposé gaussien :

$$w \sim \mathcal{N}(0, Q_0^{-1}), \quad (7.9)$$

où Q_0 désigne la matrice de précision *a priori*.

Avec l'approximation de Vecchia,

$$Q_0 = \tilde{R}^\top \tilde{R}. \quad (7.10)$$

À une constante indépendante de w près, la log-densité *a priori* s'écrit

$$\log p(w) = -\frac{1}{2} w^\top Q_0 w = -\frac{1}{2} \|\tilde{R}w\|^2. \quad (7.11)$$

7.1.3 Distribution *a posteriori*

D'après la formule de Bayes,

$$p(w | y, \beta) = \frac{p(y | w, \beta) p(w)}{p(y | \beta)}. \quad (7.12)$$

Le terme $p(y | \beta)$ étant indépendant de w ,

$$p(w | y, \beta) \propto p(y | w, \beta) p(w). \quad (7.13)$$

En combinant la vraisemblance de Poisson et la loi *a priori* gaussienne,

$$p(w | y, \beta) \propto \left[\prod_{i=1}^n \lambda_i^{y_i} \exp(-\lambda_i) \right] \exp \left(-\frac{1}{2} w^\top Q_0 w \right). \quad (7.14)$$

À une constante additive près,

$$\log p(w \mid y, \beta) = \sum_{i=1}^n [y_i \eta_i - \exp(\eta_i)] - \frac{1}{2} w^\top Q_0 w. \quad (7.15)$$

Contrairement au modèle gaussien, cette distribution ne possède pas une forme permettant de calculer explicitement sa moyenne et sa covariance *a posteriori*. L'inférence sur le champ latent repose donc sur une méthode MCMC.

7.1.4 Gradient et Hessienne de la log-postérieure

L'algorithme MALA exploite le gradient de la log-densité cible.
Pour une observation,

$$\frac{\partial}{\partial w_i} [y_i \eta_i - \exp(\eta_i)] = y_i - \lambda_i. \quad (7.16)$$

Par ailleurs,

$$\nabla_w \left(-\frac{1}{2} w^\top Q_0 w \right) = -Q_0 w. \quad (7.17)$$

Le gradient de la log-postérieure est donc

$$\boxed{\nabla_w \log p(w \mid y, \beta) = y - \lambda - Q_0 w} \quad (7.18)$$

où

$$\lambda = (\lambda_1, \dots, \lambda_n)^\top.$$

Avec $Q_0 = \tilde{R}^\top \tilde{R}$,

$$\nabla_w \log p(w \mid y, \beta) = y - \lambda - \tilde{R}^\top \tilde{R} w. \quad (7.19)$$

Pour caractériser la courbure locale de la distribution cible, on définit

$$D_\lambda(w) = \text{diag}(\lambda_1, \dots, \lambda_n). \quad (7.20)$$

La Hessienne de la log-postérieure est alors

$$\boxed{\nabla_w^2 \log p(w \mid y, \beta) = -[Q_0 + D_\lambda(w)]}. \quad (7.21)$$

On introduit ainsi la matrice de courbure locale

$$\boxed{Q(w) = -\nabla_w^2 \log p(w \mid y, \beta) = Q_0 + D_\lambda(w)}. \quad (7.22)$$

Cette matrice joue le rôle d'une précision dans une approximation gaussienne locale de la loi *a posteriori*. Elle ne constitue toutefois pas une matrice de précision postérieure exacte, puisque sa valeur dépend de w .

7.1.5 Du cas binaire au cas de Poisson

Dans le modèle binaire, la contribution de la vraisemblance à la courbure locale est donnée par

$$p_i(1 - p_i),$$

avec

$$0 \leq p_i(1 - p_i) \leq \frac{1}{4}.$$

Dans le modèle de Poisson, cette contribution est donnée directement par

$$\lambda_i = \exp(\eta_i).$$

Contrairement au cas binaire, cette quantité n'est pas bornée.

La courbure locale de la distribution cible peut donc varier fortement lorsque les intensités de Poisson diffèrent entre les sites.

Cette propriété rend le modèle de Poisson particulièrement intéressant pour étudier si le préconditionnement au MAP conserve son efficacité lorsque la géométrie locale de la cible devient plus hétérogène.

7.1.6 Calcul du MAP (Maximum *A Posteriori*)

Le MAP est défini par

$$w_{\text{MAP}} = \arg \max_w \log p(w \mid y, \beta). \quad (7.23)$$

Au MAP,

$$\nabla_w \log p(w_{\text{MAP}} \mid y, \beta) = 0, \quad (7.24)$$

soit

$$y - \lambda_{\text{MAP}} - Q_0 w_{\text{MAP}} = 0. \quad (7.25)$$

Le MAP est calculé numériquement par une méthode de Newton. À l'itération k ,

$$w^{(k+1)} = w^{(k)} + \left[Q_0 + D_\lambda(w^{(k)}) \right]^{-1} \left[y - \lambda(w^{(k)}) - Q_0 w^{(k)} \right]. \quad (7.26)$$

En raison du lien exponentiel, les intensités peuvent varier fortement. Une procédure de réduction du pas est donc utilisée lorsque le déplacement de Newton ne conduit pas à une augmentation de la log-postérieure.

Sur la configuration utilisée pour valider l'implémentation, le MAP converge en six itérations et la norme du gradient obtenue est de l'ordre de 10^{-11} . Cette valeur très proche de zéro confirme numériquement que la solution obtenue satisfait la condition de stationnarité.

7.1.7 Stratégies de préconditionnement

Une fois le MAP obtenu, on définit

$$D_{\lambda, \text{MAP}} = \text{diag}(\lambda_{1, \text{MAP}}, \dots, \lambda_{n, \text{MAP}}), \quad (7.27)$$

puis

$$\boxed{Q_{\text{MAP}} = Q_0 + D_{\lambda, \text{MAP}}}. \quad (7.28)$$

La matrice Q_{MAP} correspond à la courbure négative de la log-postérieure évaluée au mode. Elle fournit donc une approximation locale de la géométrie de la distribution cible, mais ne doit pas être interprétée comme une précision postérieure exacte.

Deux stratégies sont comparées :

- le préconditionnement *a priori*, construit à partir de Q_0 et correspondant au préconditionneur Q_0^{-1} ;

- le préconditionnement au MAP, construit à partir de Q_{MAP} et correspondant au préconditionneur Q_{MAP}^{-1} .

Le premier utilise uniquement la structure spatiale du prior, tandis que le second incorpore également l'information apportée par la vraisemblance de Poisson à travers sa courbure évaluée au MAP.

7.2 Protocole expérimental

7.2.1 Génération des données

Les expériences sont réalisées sur un domaine spatial bidimensionnel contenant

$$n = 10\,000$$

sites.

Les positions spatiales sont générées sur le domaine. La matrice de régression est construite sous la forme

$$X = \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}, \quad x_i \sim \mathcal{N}(0, 1). \quad (7.29)$$

Le vecteur des coefficients est

$$\beta = \begin{pmatrix} \beta_0 \\ 0.01 \end{pmatrix}. \quad (7.30)$$

Le coefficient $\beta_1 = 0.01$ est maintenu fixé dans toutes les expériences. Seul l'intercept β_0 varie dans le plan factoriel.

Le champ latent est simulé à partir d'une covariance de Matérn caractérisée par la variance marginale σ^2 , la régularité ν et l'échelle spatiale.

Comme dans le modèle binaire, le plan expérimental utilise la quantité

$$\ell^* = \frac{\ell}{\sqrt{\nu}}. \quad (7.31)$$

Le champ latent est simulé selon

$$w = \tilde{R}^{-1}z, \quad z \sim \mathcal{N}(0, I_n). \quad (7.32)$$

Les intensités sont ensuite définies par

$$\lambda_i = \exp(\beta_0 + 0.01x_i + w_i), \quad (7.33)$$

puis les observations sont générées selon

$$Y_i \sim \text{Poisson}(\lambda_i). \quad (7.34)$$

Le lien exponentiel rend le niveau des intensités particulièrement sensible à l'intercept. Les valeurs de β_0 utilisées dans le plan ont donc été choisies afin d'explorer plusieurs niveaux de comptage tout en limitant l'apparition de valeurs extrêmement élevées.

7.2.2 Initialisation et réglage des chaînes

Pour chaque jeu de données, le MAP est calculé avant l'exécution de la chaîne et utilisé comme point initial :

$$w^{(0)} = w_{\text{MAP}}. \quad (7.35)$$

Chaque chaîne comporte 10 000 itérations, dont les 2 000 premières constituent la phase de *burn-in*.

Pendant cette phase, le pas est adapté par la procédure de Robbins–Monro afin de viser un taux d'acceptation de

$$\alpha^* = 0.574. \quad (7.36)$$

Après le *burn-in*, le pas est maintenu constant pendant les 8 000 itérations restantes.

La persistance du momentum est contrôlée par le paramètre ρ .

7.2.3 Plan factoriel

Le plan expérimental vise à étudier conjointement l'influence de la structure du champ latent, du niveau moyen des intensités, de la persistance du momentum et du préconditionnement.

TABLE 7.1 – Paramètres considérés dans l'expérience factorielle du modèle de Poisson.

Paramètre	Valeurs testées
Variance marginale σ^2	0.5, 1, 2
Régularité ν	0.5, 1.5
Échelle spatiale $\ell^* = \ell/\sqrt{\nu}$	0.05, 0.2, 0.5
Intercept β_0	−1.5, −1, −0.5
Coefficient β_1	0.01 (fixé)
Persistance ρ	0, 0.5, 0.9
Préconditionnement	a priori, au MAP
Nombre de répétitions	5

Le coefficient β_1 étant fixé, il n'intervient pas dans le nombre de configurations. Le plan comporte donc

$$3 \times 2 \times 3 \times 3 \times 3 \times 2 \times 5 = 1620 \quad (7.37)$$

chaînes MCMC.

La variance marginale σ^2 contrôle l'amplitude des fluctuations du champ latent. Le paramètre ν contrôle sa régularité, tandis que ℓ^* caractérise l'échelle spatiale.

L'intercept β_0 agit directement sur les intensités de Poisson. Une augmentation de β_0 décale positivement le prédicteur linéaire et augmente généralement le niveau des comptages.

Il modifie également la courbure locale de la vraisemblance, puisque celle-ci dépend de

$$\lambda_i = \exp(\beta_0 + 0.01x_i + w_i). \quad (7.38)$$

Enfin, ρ est un paramètre algorithmique contrôlant la persistance du momentum.

Pour une même combinaison de paramètres et une même graine, les données simulées sont identiques pour les différentes valeurs de ρ et pour les deux préconditionnements. Les méthodes sont ainsi comparées sur une même réalisation du problème.

Les cinq graines correspondent à cinq réalisations simulées distinctes pour chaque combinaison des paramètres du modèle. Elles permettent de prendre en compte la variabilité associée à la

génération des positions, du champ latent, des covariables et des observations. Elles ne sont pas considérées comme des paramètres scientifiques du modèle.

7.2.4 Critères de comparaison

Pour chaque chaîne, l'ESS moyen, médian, minimal et maximal sont calculés.

Comme dans le modèle binaire, la moyenne et la variance *a posteriori* sont mises à jour en ligne sur l'ensemble des $n = 10\,000$ composantes afin de limiter le coût mémoire.

Pour chaque site i , la moyenne postérieure est estimée par

$$\hat{\mu}_i = \frac{1}{N} \sum_{t=1}^N w_i^{(t)}, \quad (7.39)$$

où $N = 8\,000$ désigne le nombre d'itérations conservées après le *burn-in*.

La variance marginale postérieure est estimée par

$$\hat{v}_i = \widehat{\text{Var}}(w_i | y) = \frac{1}{N-1} \sum_{t=1}^N \left(w_i^{(t)} - \hat{\mu}_i \right)^2. \quad (7.40)$$

L'ESS nécessite en revanche de conserver les trajectoires des composantes considérées. Afin de limiter le coût mémoire, il est évalué sur un sous-ensemble de 100 composantes régulièrement réparties dans le champ latent.

L'ESS médian est retenu comme critère principal d'efficacité, tandis que l'ESS minimal renseigne sur les composantes les plus difficiles à échantillonner.

Le taux d'acceptation, le pas final et le temps d'exécution sont également enregistrés.

La qualité de reconstruction est évaluée à partir de la RMSE du champ latent,

$$\text{RMSE}_w = \sqrt{\frac{1}{n} \sum_{i=1}^n (w_i - \hat{\mu}_i)^2}, \quad (7.41)$$

de la MAE,

$$\text{MAE}_w = \frac{1}{n} \sum_{i=1}^n |w_i - \hat{\mu}_i|, \quad (7.42)$$

et de la corrélation entre le champ latent simulé et la moyenne postérieure.

Contrairement au cas gaussien, ces critères comparent ici la reconstruction au champ latent simulé et non à une moyenne postérieure analytique.

Aucune covariance postérieure exacte n'étant disponible, l'analyse de l'incertitude repose sur les variances marginales estimées par MCMC.

7.3 Reconstruction du champ latent et incertitude postérieure

Trois configurations sont retenues afin d'illustrer des situations contrastées.

Afin de conserver une comparaison cohérente avec le modèle binaire, les mêmes combinaisons de paramètres spatiaux (σ^2, ν, ℓ^*) sont utilisées. L'intercept est fixé à

$$\beta_0 = -1$$

dans les trois configurations afin de maintenir un régime de comptage comparable et de concentrer l'analyse graphique sur la structure spatiale.

Pour chaque configuration, quatre quantités sont représentées : les observations de Poisson, le champ latent simulé, la moyenne *a posteriori* estimée par MCMC et la variance marginale *a posteriori* estimée.




FIGURE 7.1 – Observations de Poisson, champ latent simulé, moyenne *a posteriori* et variance marginale *a posteriori* estimées par MCMC pour trois configurations du modèle géostatistique de Poisson.

La Figure 7.1 permet d'évaluer conjointement la qualité de reconstruction du champ latent et l'incertitude associée.

Dans la première configuration, ($\sigma^2 = 0.5, \nu = 0.5, \ell^* = 0.05, \beta_0 = -1$), la faible régularité et la courte échelle spatiale produisent des variations relativement locales du champ latent. Les observations de comptage contiennent de nombreuses valeurs faibles ou nulles. Malgré cette information locale limitée, la moyenne postérieure retrouve les principales structures du champ latent.

Les amplitudes sont toutefois atténuées par rapport au champ simulé. Cette contraction traduit l'effet conjoint de la vraisemblance et de la régularisation spatiale introduite par le prior.

Dans la deuxième configuration, ($\sigma^2 = 1, \nu = 1.5, \ell^* = 0.2, \beta_0 = -1$), la structure spatiale

est plus régulière et plus étendue. Les grandes zones de valeurs faibles et élevées observées dans le champ latent sont clairement retrouvées dans la moyenne postérieure.

Dans la troisième configuration, ($\sigma^2 = 2, \nu = 1.5, \ell^* = 0.5, \beta_0 = -1$), le champ latent présente des structures spatiales encore plus étendues. La moyenne postérieure reproduit nettement cette organisation générale malgré la nature discrète des observations.

Cette situation illustre le rôle de la dépendance spatiale : l'estimation de w_i ne repose pas uniquement sur le comptage observé au site i , mais également sur l'information apportée par les autres sites à travers la structure de dépendance du champ latent.

Les cartes de variance marginale montrent par ailleurs que l'incertitude postérieure n'est pas homogène dans l'espace. Certaines régions présentent des niveaux de dispersion plus élevés que d'autres. Ces observations restent toutefois descriptives : les figures seules ne permettent pas d'attribuer ces variations à un mécanisme particulier.

Enfin, plusieurs paramètres varient simultanément entre les trois configurations. Ces représentations permettent donc d'illustrer différents régimes spatiaux, mais ne permettent pas d'isoler graphiquement l'effet propre de chacun des paramètres.

Les échelles de couleurs étant adaptées séparément à chaque carte, les comparaisons quantitatives doivent s'appuyer sur les valeurs indiquées dans les légendes plutôt que sur les couleurs seules.

7.4 Analyse de l'incertitude postérieure

Comme dans le modèle binaire, la moyenne postérieure ne suffit pas à caractériser complètement la reconstruction du champ latent.

Pour chaque site i , la variance marginale

$$\widehat{\text{Var}}(w_i \mid y) \quad (7.43)$$

mesure la dispersion des valeurs de w_i visitées par la chaîne après le *burn-in*.

Une variance faible correspond à une distribution postérieure plus concentrée autour de sa moyenne, tandis qu'une variance plus élevée traduit une incertitude plus importante.

Il est essentiel de distinguer cette quantité de l'erreur de reconstruction. La variance postérieure n'est pas définie par

$$(w_i - \hat{\mu}_i)^2.$$

Une région présentant une variance élevée peut donc être correctement reconstruite tout en restant associée à une incertitude importante.

Dans le modèle de Poisson, la contribution locale de la vraisemblance à la courbure dépend de

$$\lambda_i = \exp(x_i^\top \beta + w_i). \quad (7.44)$$

La courbure négative de la log-postérieure est donnée par

$$-\nabla_w^2 \log p(w \mid y, \beta) = Q_0 + D_\lambda(w). \quad (7.45)$$

Cette expression permet de comprendre qualitativement comment l'information apportée par les observations se combine avec la structure spatiale du prior. Elle ne fournit toutefois pas directement la covariance marginale exacte de la distribution *a posteriori*.

En particulier,

$$Q_{\text{MAP}}^{-1}$$

constitue uniquement une approximation gaussienne locale de la covariance autour du mode.

Sur l'ensemble du plan factoriel, les variances postérieures moyennes restent proches entre les différentes stratégies.

TABLE 7.2 – Variance postérieure marginale moyenne selon la persistance et le préconditionnement.

Préconditionnement	ρ	Variance moyenne
A priori	0	0.2156
A priori	0.5	0.2180
A priori	0.9	0.2197
Au MAP	0	0.2212
Au MAP	0.5	0.2214
Au MAP	0.9	0.2211

Ces valeurs doivent être interprétées avec précaution. La variance postérieure est avant tout une caractéristique de la distribution cible et non un critère direct de performance de l'algorithme.

Les différentes stratégies de préconditionnement ciblant la même distribution, on s'attend à ce que des chaînes suffisamment bien mélangées fournissent des estimations compatibles de cette variance.

Une variance moyenne plus faible ne signifie donc pas qu'une stratégie MCMC est meilleure.

Contrairement au modèle gaussien, aucune expression analytique exacte de la variance postérieure n'est disponible ici. Il n'est donc pas possible de calculer une RMSE de variance par rapport à une référence exacte.

Une étude plus approfondie de la précision Monte-Carlo de ces estimations nécessiterait par exemple des chaînes de référence beaucoup plus longues, plusieurs chaînes indépendantes ou des diagnostics portant directement sur les quantités quadratiques du champ latent.

7.5 Analyse de l'efficacité de l'échantillonnage

L'analyse précédente porte sur la reconstruction et l'incertitude estimées à partir des chaînes. On étudie maintenant l'efficacité avec laquelle les différentes stratégies explorent la distribution cible.

Comme dans les chapitres précédents, l'objectif n'est pas uniquement d'identifier la stratégie atteignant ponctuellement le plus grand ESS, mais de rechercher une méthode conservant de bonnes performances lorsque les paramètres du modèle varient.

7.5.1 Comparaison globale des préconditionnements

Le Tableau 7.3 présente les performances moyennes obtenues sur l'ensemble du plan expérimental.

TABLE 7.3 – Performances moyennes des deux stratégies de préconditionnement dans le modèle de Poisson.

Précond.	ESS méd.	ESS min.	RMSE champ	MAE champ	Corr.	Temps (s)
A priori	177.86	110.61	0.438	0.344	0.827	10.94
Au MAP	394.45	300.29	0.435	0.341	0.829	11.08

Sur l'ensemble du plan expérimental, le préconditionnement au MAP présente une efficacité statistique nettement supérieure.

L'ESS médian moyen passe de

177.86

avec le préconditionnement *a priori* à

394.45

avec le préconditionnement au MAP, soit un facteur d'environ 2.2.

L'ESS minimal moyen augmente également fortement, passant de 110.61 à 300.29. Le gain concerne donc également les composantes les plus difficiles à échantillonner.

Ainsi, pour un taux d'acceptation comparable, la prise en compte de la courbure locale au MAP autorise des déplacements plus importants dans l'espace des états.

Les critères de reconstruction restent par ailleurs très proches. La RMSE du champ passe seulement de 0.438 à 0.435, la MAE de 0.344 à 0.341, et les corrélations moyennes sont respectivement égales à 0.827 et 0.829.

Ce résultat est cohérent avec le fait que les deux algorithmes ciblent la même distribution *a posteriori*. Le principal gain du préconditionnement au MAP concerne donc l'efficacité avec laquelle cette distribution est explorée pour une longueur de chaîne donnée.

Les temps moyens d'exécution restent enfin très proches, ce qui indique que le gain d'ESS n'est pas associé ici à une augmentation importante du coût moyen de calcul.

7.5.2 Performance et robustesse des stratégies

La Figure 7.2 présente la distribution de l'ESS médian selon la persistance du momentum ρ et le préconditionnement.




FIGURE 7.2 – Distribution de l'ESS médian selon la persistance du momentum ρ et la stratégie de préconditionnement dans le modèle de Poisson.

Le premier décile Q_{10} est utilisé comme indicateur de robustesse. Il correspond au niveau d'ESS en dessous duquel se situent 10 % des configurations et permet donc de caractériser le comportement de la stratégie dans la partie la moins favorable du plan expérimental.

Le Tableau 7.4 résume la distribution de l'ESS médian pour les six combinaisons considérées.

TABLE 7.4 – Résumé de l’ESS médian selon la stratégie MALA dans le modèle de Poisson.

Stratégie	ρ	Moyenne	Médiane	Écart-type	Q_{10}	Minimum
A priori	0	119.81	85.97	93.75	34.23	12.66
A priori	0.5	180.53	131.86	141.25	47.05	15.33
A priori	0.9	233.26	188.19	157.51	59.56	21.83
Au MAP	0	337.05	340.63	14.11	320.22	282.22
Au MAP	0.5	483.13	486.73	38.49	436.26	353.53
Au MAP	0.9	363.16	352.17	83.64	270.23	154.19

Avec le préconditionnement *a priori*, l’augmentation de la persistance du momentum améliore progressivement l’ESS moyen. Cependant, les distributions restent très dispersées.

Pour $\rho = 0.9$, l’ESS médian moyen atteint environ 233, mais l’écart-type est proche de 158 et le minimum reste inférieur à 22.

Le préconditionnement au MAP produit des performances nettement plus homogènes.

Pour $\rho = 0$, l’ESS médian moyen est déjà d’environ 337, avec un écart-type faible.

La meilleure combinaison entre niveau de performance et robustesse est obtenue pour

$$\rho = 0.5.$$

Dans ce cas, l’ESS médian moyen atteint

$$483.13,$$

la médiane globale

$$486.73,$$

et le premier décile

$$Q_{10} = 436.26.$$

Ainsi, environ 90 % des configurations présentent un ESS médian supérieur à 436 pour cette stratégie.

Même le minimum observé reste élevé :

$$353.53.$$

Lorsque $\rho = 0.9$, l’ESS médian moyen diminue à environ 363 et la dispersion augmente nettement.

Ces résultats indiquent qu’une persistance très élevée n’est pas systématiquement favorable lorsque le préconditionnement décrit déjà efficacement la géométrie locale.

Dans le modèle de Poisson, la combinaison

$$Q_{\text{MAP}} + \rho = 0.5$$

apparaît donc comme le meilleur compromis entre performance et robustesse parmi les stratégies étudiées.

7.5.3 Influence des paramètres du modèle

Afin de compléter l’analyse globale, un modèle linéaire est ajusté avec l’ESS médian comme variable réponse.

Le facteur *seed* est introduit comme facteur de contrôle afin de tenir compte de la variabilité entre les cinq réalisations. Il n’est pas interprété comme un paramètre scientifique du modèle.

Le modèle considéré est

$$\begin{aligned} \text{ESS}_{\text{med}} \sim & \text{seed} + \sigma^2 \times \text{prconditionnement} + \nu \times \text{prconditionnement} \\ & + \ell^* \times \text{prconditionnement} + \beta_0 \times \text{prconditionnement} + \rho \times \text{prconditionnement}. \end{aligned} \quad (7.46)$$

Le modèle est globalement hautement significatif,

$$p < 2.2 \times 10^{-16},$$

et explique une part importante de la variabilité observée :

$$R^2 = 0.8517, \quad R^2_{\text{ajust}} = 0.8496.$$

```
Call:
lm(formula = ess_median ~ seed + sigma2 * conditioning_factor +
    nu * conditioning_factor + range * conditioning_factor +
    beta0 * conditioning_factor + rho * conditioning_factor,
    data = experiment_results_df)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-199.048	-35.926	-1.383	29.780	273.115

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	351.8689	7.4896	46.981	< 2e-16	***
seed2	2.8480	4.8345	0.589	0.55588	
seed3	-26.3019	4.8345	-5.440	6.14e-08	***
seed4	10.7949	4.8345	2.233	0.02569	*
seed5	-16.9712	4.8345	-3.510	0.00046	***
sigma21	-121.3996	5.2959	-22.923	< 2e-16	***
sigma22	-209.9971	5.2959	-39.653	< 2e-16	***
conditioning_factorMAP	-0.4331	9.6690	-0.045	0.96427	
nu1.5	32.1996	4.3241	7.447	1.56e-13	***
range0.2	-104.7812	5.2959	-19.785	< 2e-16	***
range0.5	-137.3669	5.2959	-25.938	< 2e-16	***
beta0-1	-54.1090	5.2959	-10.217	< 2e-16	***
beta0-0.5	-99.0387	5.2959	-18.701	< 2e-16	***
rho0.5	60.7152	5.2959	11.465	< 2e-16	***
rho0.9	113.4432	5.2959	21.421	< 2e-16	***
sigma21:conditioning_factorMAP	113.4732	7.4896	15.151	< 2e-16	***
sigma22:conditioning_factorMAP	193.9541	7.4896	25.897	< 2e-16	***
conditioning_factorMAP:nu1.5	-29.3119	6.1152	-4.793	1.79e-06	***
conditioning_factorMAP:range0.2	110.1032	7.4896	14.701	< 2e-16	***
conditioning_factorMAP:range0.5	143.4909	7.4896	19.159	< 2e-16	***
conditioning_factorMAP:beta0-1	39.7158	7.4896	5.303	1.30e-07	***
conditioning_factorMAP:beta0-0.5	96.2302	7.4896	12.849	< 2e-16	***
conditioning_factorMAP:rho0.5	85.3670	7.4896	11.398	< 2e-16	***
conditioning_factorMAP:rho0.9	-87.3252	7.4896	-11.660	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 61.53 on 1596 degrees of freedom
Multiple R-squared: 0.8517, Adjusted R-squared: 0.8496
F-statistic: 398.6 on 23 and 1596 DF, p-value: < 2.2e-16

FIGURE 7.3 – Résultats du modèle linéaire expliquant les variations de l'ESS médian dans le modèle de Poisson.

Les résultats mettent en évidence plusieurs interactions importantes entre les paramètres du modèle et le préconditionnement. En présence de telles interactions, les effets principaux doivent être interprétés relativement à la stratégie de référence.

Avec le préconditionnement *a priori*, l'augmentation de σ^2 dégrade fortement l'ESS médian. Les coefficients associés à $\sigma^2 = 1$ et $\sigma^2 = 2$ sont respectivement

$$-121.40$$

et

$$-210.00.$$

Les interactions correspondantes avec le préconditionnement au MAP sont positives, respectivement égales à

$$+113.47$$

et

$$+193.95.$$

Pour $\sigma^2 = 1$, l'effet total estimé avec le préconditionnement au MAP devient donc

$$-121.40 + 113.47 = -7.93,$$

tandis que pour $\sigma^2 = 2$ il devient

$$-210.00 + 193.95 = -16.05.$$

La sensibilité de l'ESS à l'augmentation de la variance spatiale est donc fortement réduite avec le préconditionnement au MAP.

Un comportement analogue apparaît pour l'échelle spatiale.

Par rapport à $\ell^* = 0.05$, les effets associés à $\ell^* = 0.2$ et $\ell^* = 0.5$ sont respectivement

$$-104.78$$

et

$$-137.37$$

avec le préconditionnement de référence.

Les interactions avec le MAP sont

$$+110.10$$

et

$$+143.49.$$

Les effets totaux deviennent donc approximativement

$$-104.78 + 110.10 = 5.32$$

et

$$-137.37 + 143.49 = 6.12.$$

La dépendance des performances à l'échelle spatiale est ainsi presque entièrement compensée dans le modèle ajusté lorsque le préconditionnement au MAP est utilisé.

L'intercept β_0 influence également les performances.

Par rapport à la modalité de référence $\beta_0 = -1.5$, les effets principaux associés à $\beta_0 = -1$ et $\beta_0 = -0.5$ sont respectivement

$$-54.11$$

et

$$-99.04.$$

Les interactions correspondantes avec le MAP sont positives :

$$+39.72$$

et

$$+96.23.$$

Les effets totaux deviennent ainsi

$$-54.11 + 39.72 = -14.39$$

pour $\beta_0 = -1$, et

$$-99.04 + 96.23 = -2.81$$

pour $\beta_0 = -0.5$.

Le préconditionnement au MAP atténue donc fortement la sensibilité de l'ESS au niveau moyen des intensités.

Enfin, l'interaction entre le préconditionnement et ρ confirme les résultats observés précédemment.

Le passage de $\rho = 0$ à $\rho = 0.5$ produit un effet principal de

$$+60.72,$$

auquel s'ajoute une interaction avec le MAP égale à

$$+85.37.$$

L'effet total estimé avec le préconditionnement au MAP est donc

$$60.72 + 85.37 = 146.09.$$

Pour $\rho = 0.9$, l'effet principal vaut

$$+113.44,$$

mais l'interaction avec le MAP devient négative :

$$-87.33.$$

L'effet total reste alors positif mais beaucoup plus faible :

$$113.44 - 87.33 = 26.11.$$

Ces résultats confirment que l'effet de la persistance du momentum dépend fortement du préconditionnement utilisé.

Dans l'ensemble, le modèle linéaire suggère que le préconditionnement au MAP compense une part importante de l'effet des changements de géométrie induits par plusieurs paramètres du modèle sur l'efficacité de l'échantillonnage.

7.6 Discussion des résultats

L'application au modèle de Poisson confirme que les conclusions obtenues dans le modèle binaire ne reposent pas uniquement sur la vraisemblance Bernoulli-logistique.

Dans les deux modèles, l'utilisation de la courbure locale de la log-postérieure au MAP permet de construire un préconditionnement mieux adapté à la géométrie de la cible que celui reposant uniquement sur la loi *a priori*.

Le modèle de Poisson présente toutefois une géométrie différente. La contribution de la vraisemblance à la courbure est donnée par λ_i , alors que dans le modèle binaire elle est donnée par $p_i(1 - p_i)$ et reste bornée.

Les intensités de Poisson peuvent donc introduire des différences de courbure plus importantes entre les sites.

Malgré cette différence, le préconditionnement au MAP reste nettement plus efficace. Il augmente fortement l'ESS médian et l'ESS minimal tout en conservant des taux d'acceptation et des temps de calcul proches de ceux du préconditionnement *a priori*.

Les critères de reconstruction restent également similaires entre les deux stratégies. Le gain concerne donc principalement l'efficacité avec laquelle la distribution cible est explorée, plutôt qu'une modification systématique de la reconstruction obtenue.

L'étude de la persistance du momentum conduit elle aussi à une conclusion similaire à celle obtenue dans le modèle binaire. Une persistance intermédiaire,

$$\rho = 0.5,$$

associée au préconditionnement au MAP fournit un meilleur compromis qu'une absence de persistance ou qu'une persistance très élevée.

L'analyse de l'incertitude complète enfin cette comparaison. Les cartes de variance marginale fournissent une information distincte de celle apportée par la moyenne postérieure. Elles décrivent la dispersion résiduelle du champ latent conditionnellement aux observations et ne doivent pas être interprétées comme des cartes d'erreur.

Ainsi, la stratégie la plus intéressante n'est pas uniquement celle qui atteint ponctuellement un ESS élevé, mais celle qui maintient un niveau d'efficacité important dans une grande variété de configurations.

Dans le plan expérimental étudié, cette propriété est clairement observée pour le préconditionnement au MAP associé à $\rho = 0.5$.

Conclusion

Ce chapitre a permis d'étendre l'étude à un modèle géostatistique de Poisson, fournissant ainsi un second cadre non gaussien distinct du modèle binaire.

La loi *a posteriori* du champ latent n'étant pas disponible analytiquement, son gradient et sa Hessienne ont été utilisés pour caractériser sa géométrie locale. La courbure évaluée au MAP permet de construire un préconditionnement fixe intégrant à la fois la structure spatiale du prior et l'information apportée par les observations.

Sur l'ensemble du plan factoriel, le préconditionnement au MAP améliore fortement l'efficacité de l'échantillonnage. L'ESS médian moyen passe de

177.86

avec le préconditionnement *a priori* à

394.45

avec le préconditionnement au MAP.

L'ESS minimal moyen passe parallèlement de

110.61

à

300.29.

Ces gains sont obtenus avec des taux d'acceptation et des temps moyens de calcul très proches. L'analyse de robustesse met plus particulièrement en évidence la combinaison

$$Q_{\text{MAP}} + \rho = 0.5$$

pour laquelle l'ESS médian moyen atteint environ

483,

avec

$$Q_{10} \simeq 436$$

et un minimum supérieur à

353.

Le modèle linéaire confirme que le préconditionnement au MAP réduit fortement la sensibilité des performances à plusieurs paramètres du modèle, notamment σ^2 , ℓ^* et β_0 .

L'analyse de la variance marginale postérieure complète cette étude en permettant de caractériser l'incertitude associée à la reconstruction du champ latent. Contrairement au cas gaussien, cette variance ne peut toutefois pas être comparée à une référence analytique exacte.

Ainsi, la conclusion obtenue dans le modèle binaire se retrouve dans un modèle d'observation de nature différente et présentant une géométrie locale plus hétérogène.

Dans le domaine expérimental considéré, le préconditionnement construit à partir de la courbure au MAP, associé à une persistance intermédiaire du momentum $\rho = 0.5$, apparaît donc comme la stratégie la plus performante et la plus robuste parmi celles étudiées.

Ce résultat renforce l'idée que l'utilisation d'une approximation locale de la géométrie *a posteriori* peut améliorer substantiellement l'échantillonnage de champs latents de grande dimension dans différents modèles géostatistiques non gaussiens.

Chapitre 8

Conclusion générale, limites et perspectives

Ce mémoire s’est intéressé à l’échantillonnage efficace de champs latents dans des modèles géostatistiques bayésiens de grande dimension. La problématique centrale du stage était d’identifier une stratégie MALA à la fois performante et robuste, c’est-à-dire capable de produire des échantillons faiblement autocorrélés tout en conservant de bonnes performances lorsque les caractéristiques du modèle varient.

Le travail s’est concentré sur trois mécanismes susceptibles d’améliorer l’efficacité de l’échantillonnage : l’adaptation automatique du pas de proposition, le préconditionnement et la persistance du momentum.

La démarche a été menée progressivement. Le modèle géostatistique gaussien a d’abord fourni un cadre contrôlé, dans lequel la distribution *a posteriori* du champ latent est connue analytiquement. Cette propriété a permis de valider l’implémentation et de comparer directement les estimations MCMC de la moyenne et de la variance aux quantités exactes.

L’étude a ensuite été étendue au modèle géostatistique binaire. Dans ce cas, la distribution *a posteriori* n’est plus gaussienne et sa courbure dépend du champ latent. Le calcul du MAP et de la Hessienne de la log-postérieure a permis de construire une approximation locale de cette géométrie et de définir un préconditionnement adapté au cas non gaussien.

Enfin, un modèle géostatistique de Poisson avec lien logarithmique a été considéré afin d’évaluer si les conclusions obtenues dans le modèle binaire se maintenaient lorsque la loi d’observation et la géométrie de la cible étaient modifiées. Dans ce modèle, la contribution de la vraisemblance à la courbure dépend directement de l’intensité de Poisson et n’est pas uniformément bornée.

8.1 Principaux enseignements

Les expériences réalisées mettent en évidence trois conclusions principales.

Premièrement, le préconditionnement joue un rôle déterminant dans l’efficacité de l’échantillonnage. Dans le modèle gaussien, la stratégie utilisant la matrice identité conduit à des tailles effectives d’échantillon faibles et, pour une longueur de chaîne donnée, à des estimations Monte-Carlo moins précises des caractéristiques de la distribution *a posteriori*.

Les préconditionnements construits à partir de la structure du prior ou de la géométrie *a posteriori* améliorent fortement l’ESS et réduisent les erreurs d’estimation de la moyenne et de la variance.

La disponibilité d’une solution analytique dans le modèle gaussien a permis d’évaluer directement cette amélioration. La combinaison du préconditionnement *a posteriori* avec

$$\rho = 0.5$$

présente notamment une RMSE moyenne sur les variances marginales d'environ

0.016,

une erreur relative moyenne proche de

3.9 %,

et une proportion empirique de couverture des intervalles ponctuels proche de

94.7 %.

Cette dernière quantité doit toutefois être interprétée comme un indicateur descriptif obtenu sur les sites simulés, ceux-ci appartenant à un même champ spatial et n'étant pas indépendants.

Deuxièmement, dans les modèles non gaussiens, l'utilisation de la courbure locale au MAP fournit un préconditionnement beaucoup plus robuste que celui construit uniquement à partir du prior.

Dans le modèle binaire, l'ESS médian moyen passe d'environ

76

avec le préconditionnement *a priori* à environ

164

avec le préconditionnement au MAP.

La combinaison

$$Q_{\text{MAP}} + \rho = 0.5$$

atteint un ESS médian moyen d'environ

213,

avec un premier décile proche de

191.

Le préconditionnement au MAP réduit également fortement la sensibilité de l'efficacité de la chaîne aux paramètres décrivant le champ spatial.

Troisièmement, les conclusions obtenues dans le modèle binaire se retrouvent dans le modèle de Poisson malgré une géométrie différente.

Dans ce dernier modèle, l'ESS médian moyen passe de

177.86

avec le préconditionnement *a priori* à

394.45

avec le préconditionnement au MAP. L'ESS minimal moyen passe parallèlement de

110.61

à

300.29.

Ces gains sont obtenus avec des taux d'acceptation très proches :

0.574

pour le préconditionnement *a priori* et

0.568

pour le préconditionnement au MAP.

Le pas moyen utilisé par l'algorithme est en revanche nettement plus élevé avec le préconditionnement au MAP :

0.520

contre

0.182.

Ainsi, pour un taux d'acceptation comparable, la prise en compte de la courbure locale permet à la chaîne d'effectuer des déplacements plus importants dans l'espace des états.

Les critères de reconstruction restent néanmoins très proches entre les deux préconditionnements. Dans le modèle de Poisson, la RMSE moyenne du champ est d'environ

0.438

avec le préconditionnement *a priori* et

0.435

avec le préconditionnement au MAP.

Ce résultat est cohérent avec le fait que les deux stratégies ciblent la même distribution. Leur différence concerne principalement l'efficacité avec laquelle cette distribution est explorée.

Enfin, l'étude de la persistance du momentum montre qu'une valeur élevée de ρ n'est pas systématiquement favorable. Dans les modèles binaire et de Poisson, une persistance intermédiaire,

$$\rho = 0.5,$$

associée au préconditionnement au MAP offre le meilleur compromis parmi les valeurs étudiées.

Dans le modèle de Poisson, cette combinaison conduit à un ESS médian moyen d'environ

483,

avec

$$Q_{10} \simeq 436$$

et un minimum supérieur à

353.

Ces résultats montrent que la stratégie reste performante y compris dans les configurations les moins favorables du plan expérimental.

8.2 Apport de l'analyse de l'incertitude postérieure

Une extension importante du travail a consisté à ne plus limiter l'analyse à la moyenne *a posteriori* du champ latent.

Dans le modèle gaussien, la covariance exacte

$$\Sigma_{\text{post}} = Q_{\text{post}}^{-1}$$

est disponible analytiquement. Les variances marginales estimées par MCMC ont donc pu être comparées directement aux éléments diagonaux de cette matrice.

Cette analyse a montré qu'un mauvais mélange de la chaîne affecte non seulement l'estimation de la moyenne, mais également celle de la dispersion de la distribution cible pour une longueur de chaîne finie.

Les stratégies préconditionnées fournissent des estimations beaucoup plus proches des variances analytiques que la stratégie utilisant la matrice identité.

Dans les modèles binaire et de Poisson, aucune covariance *a posteriori* exacte n'est disponible. Les variances marginales ont donc été estimées directement à partir des tirages MCMC.

Les cartes obtenues montrent que l'incertitude n'est pas spatialement homogène. Elles apportent une information différente de celle fournie par la moyenne postérieure.

Une variance élevée indique que la distribution conditionnelle du champ latent reste relativement dispersée au site considéré. Elle ne signifie pas nécessairement que la moyenne postérieure est éloignée du champ latent simulé.

Dans le modèle de Poisson, les variances postérieures moyennes restent très proches entre les différents préconditionnements. Cette observation est cohérente avec le fait que les stratégies étudiées ciblent la même distribution *a posteriori*.

La variance postérieure ne constitue donc pas, à elle seule, un critère de performance de l'algorithme. L'évaluation de la qualité de son estimation Monte-Carlo nécessite des diagnostics complémentaires.

8.3 Limites de l'étude

Les résultats obtenus doivent être interprétés dans le cadre du protocole expérimental considéré.

Une première limite tient au fait que l'étude repose exclusivement sur des données simulées. Ce choix permet de connaître le champ latent ayant généré les observations, de contrôler précisément les paramètres du modèle et de comparer directement les reconstructions au champ simulé.

Il ne reproduit cependant pas toutes les difficultés susceptibles d'apparaître sur des données réelles, telles qu'une mauvaise spécification du modèle, des covariables imparfaitement mesurées ou des structures spatiales plus complexes.

Une deuxième limite concerne les paramètres du modèle. Les coefficients de régression et les paramètres de covariance sont considérés comme connus pendant l'échantillonnage du champ latent.

L'étude porte donc sur une étape particulière de l'inférence bayésienne. Dans une analyse complète, ces paramètres devraient eux-mêmes être estimés conjointement avec le champ latent, ce qui augmenterait la dimension du problème et introduirait de nouvelles dépendances dans la distribution cible.

Dans les modèles non gaussiens, le préconditionnement au MAP repose également sur une approximation locale de la géométrie de la postérieure.

Dans le modèle binaire,

$$Q_{\text{MAP}} = Q_0 + D_{\text{MAP}}, \quad (8.1)$$

tandis que dans le modèle de Poisson,

$$Q_{\text{MAP}} = Q_0 + D_{\lambda, \text{MAP}}. \quad (8.2)$$

Ces matrices correspondent à la courbure négative de la log-postérieure évaluée au mode. Elles sont ensuite maintenues fixes pendant toute la chaîne.

Elles fournissent donc une approximation locale de la géométrie et non une description exacte de la courbure sur l'ensemble de l'espace des états.

Cette approximation présente l'avantage de rester numériquement accessible en grande dimension, mais elle ne prend pas en compte les variations de courbure rencontrées au cours de l'échantillonnage.

Une autre limite concerne le calcul de l'ESS dans les expériences non gaussiennes. Pour des champs de dimension

$$n = 10\,000,$$

les trajectoires de seulement 100 composantes régulièrement réparties sont conservées pour ce diagnostic.

Ce choix réduit fortement le coût mémoire, notamment lors de l'exécution parallèle des chaînes, mais l'ESS ainsi résumé ne décrit pas nécessairement toutes les composantes du champ latent.

Les moyennes et les variances marginales postérieures sont en revanche estimées sur l'ensemble des 10 000 composantes.

L'évaluation de l'incertitude constitue également une limite dans les modèles non gaussiens. Contrairement au cadre gaussien, aucune expression analytique des variances marginales postérieures n'est disponible.

Les cartes obtenues permettent donc de caractériser l'incertitude estimée par MCMC, mais leur erreur Monte-Carlo ne peut pas être évaluée directement par comparaison à une référence exacte.

Enfin, les conclusions dépendent des valeurs retenues dans les différents plans factoriels. Les niveaux de ν , ℓ^* , τ^2 , σ^2 , β_0 et ρ permettent d'explorer plusieurs régimes contrastés, mais ne couvrent pas l'ensemble des situations possibles.

Les résultats doivent donc être interprétés comme une analyse de performance et de robustesse sur le domaine expérimental considéré, et non comme des propriétés universelles des méthodes étudiées.

8.4 Difficultés méthodologiques et numériques

Une difficulté majeure du travail a été liée à la dimension des champs latents. Les expériences non gaussiennes portent sur

$$10\,000$$

variables latentes et les plans factoriels comportent jusqu'à

$$1620$$

chaînes MCMC.

Une implémentation reposant sur des matrices de covariance denses aurait rapidement conduit à des coûts de calcul et de mémoire prohibitifs.

L'approximation de Vecchia et l'utilisation de matrices creuses ont donc joué un rôle essentiel. La représentation

$$Q_0 = \tilde{R}^\top \tilde{R}$$

permet notamment d'utiliser des factorisations de Cholesky creuses et des résolutions de systèmes linéaires sans former explicitement l'inverse des matrices de précision.

La construction du préconditionnement dans les modèles non gaussiens a constitué une autre difficulté importante.

Contrairement au modèle gaussien, aucune précision *a posteriori* constante n'est disponible. Il a donc été nécessaire de calculer le gradient et la Hessienne de la log-postérieure, de déterminer numériquement le MAP puis d'utiliser la courbure obtenue au mode pour construire un préconditionnement fixe.

Le modèle de Poisson introduit en outre une difficulté numérique spécifique. En raison du lien logarithmique,

$$\lambda_i = \exp(x_i^\top \beta + w_i), \quad (8.3)$$

les intensités peuvent augmenter rapidement et conduire à des variations importantes de la courbure.

Le calcul du MAP a donc été stabilisé par une méthode de Newton associée à une procédure de réduction du pas lorsque la mise à jour proposée n'améliore pas la log-postérieure.

Le réglage du pas de l'algorithme constitue également un enjeu pratique. Un pas trop faible produit des déplacements limités et fortement autocorrélés, tandis qu'un pas trop élevé augmente la probabilité de rejet.

L'adaptation de type Robbins–Monro pendant le *burn-in* a permis d'automatiser ce réglage et d'assurer des comparaisons plus homogènes entre les différentes configurations.

Enfin, le nombre important de chaînes a rendu nécessaire la parallélisation des expériences. Cette organisation a réduit le temps global de calcul, mais a également nécessité une gestion attentive de la mémoire, des dépendances logicielles et des graines aléatoires afin de préserver la reproductibilité des simulations.

8.5 Perspectives

Plusieurs prolongements peuvent être envisagés à partir de ce travail.

Une première perspective consiste à ne plus supposer connus les paramètres de covariance et les coefficients de régression. Une inférence bayésienne complète conduirait à échantillonner conjointement le champ latent, les paramètres de covariance de Matérn et les coefficients de régression.

Cette extension rapprocherait le cadre expérimental d'une application réelle, mais augmenterait la dimension de la distribution cible et pourrait introduire des dépendances supplémentaires entre les paramètres.

Une deuxième perspective concerne le préconditionnement dans les modèles non gaussiens. Les matrices Q_{MAP} utilisées dans ce travail constituent des approximations fixes de la géométrie de la postérieure.

Une extension naturelle serait d'étudier des méthodes utilisant une métrique dépendant de l'état courant, telles que les approches de type *Riemannian Manifold MALA*.

Ces méthodes pourraient mieux suivre les variations locales de courbure de la distribution cible. Leur intérêt devrait toutefois être évalué en tenant compte du coût supplémentaire associé au calcul et à la factorisation répétée de la métrique en grande dimension.

Il serait également intéressant d'étudier plus systématiquement le choix de la persistance du momentum.

Les expériences montrent que l'effet de ρ dépend fortement du préconditionnement : une valeur intermédiaire est favorable aux stratégies fondées sur la courbure au MAP, tandis qu'une persistance trop élevée peut dégrader les performances.

Une adaptation conjointe du pas et de la persistance pourrait donc constituer une piste de recherche intéressante.

L'analyse de l'incertitude pourrait également être approfondie dans les modèles non gaussiens. Des chaînes de référence plus longues, plusieurs chaînes indépendantes ou l'étude de diagnostics appliqués aux quantités quadratiques telles que w_i^2 permettraient de mieux évaluer la précision Monte-Carlo des estimations de variance.

Une autre perspective consiste à étendre la démarche à d'autres lois d'observation non gaussiennes présentant des géométries différentes. Des modèles binomiaux négatifs pourraient notamment être considérés pour des données de comptage surdispersées. Des modèles adaptés aux données censurées ou aux variables positives continues constitueraient également des extensions possibles.

Enfin, l'application à des données géostatistiques réelles représente une étape importante. Elle permettrait d'évaluer la robustesse des stratégies étudiées lorsque la structure spatiale est moins contrôlée, lorsque les covariables sont imparfaites et lorsque le modèle statistique constitue nécessairement une approximation du phénomène observé.

Conclusion

Ce travail a permis d'étudier différentes stratégies d'échantillonnage de champs latents géostatistiques de grande dimension à partir d'une variante préconditionnée de MALA avec persistance du momentum.

Le modèle gaussien a d'abord fourni un cadre analytique permettant de valider l'implémentation, aussi bien pour l'estimation de la moyenne que pour celle de l'incertitude *a posteriori*.

La démarche a ensuite été étendue à deux modèles non gaussiens : un modèle Bernoulli-logistique et un modèle de Poisson avec lien logarithmique. Dans ces deux cas, la géométrie de la loi *a posteriori* dépend du champ latent. Une approximation locale construite à partir de la Hessienne évaluée au MAP a donc été utilisée pour définir le préconditionnement.

Les résultats montrent que le préconditionnement constitue un élément déterminant de l'efficacité de l'échantillonnage.

Un préconditionnement fondé uniquement sur la structure du prior peut améliorer l'exploration de la cible, mais ses performances restent sensibles aux paramètres du modèle.

À l'inverse, le préconditionnement fondé sur la courbure au MAP réduit fortement cette sensibilité et permet généralement d'utiliser des pas plus importants tout en conservant des taux d'acceptation satisfaisants.

L'effet de la persistance du momentum dépend lui-même du préconditionnement. Dans les deux modèles non gaussiens étudiés, la combinaison

$$\boxed{Q_{\text{MAP}} + \rho = 0.5}$$

offre le meilleur compromis entre niveau d'ESS et stabilité des performances parmi les configurations considérées.

Dans le modèle binaire, cette stratégie atteint un ESS médian moyen d'environ

$$213,$$

tandis que dans le modèle de Poisson il atteint environ

$$483.$$

L'étude de l'incertitude *a posteriori* complète enfin l'analyse fondée sur l'efficacité de l'échantillonnage et la reconstruction du champ latent.

Dans le modèle gaussien, la disponibilité d'une référence analytique permet de vérifier directement la qualité des estimations de variance.

Dans les modèles non gaussiens, les cartes de variance marginale apportent une information complémentaire sur la dispersion du champ latent conditionnellement aux observations, même si leur précision Monte-Carlo ne peut pas être validée de la même manière.

Au regard de la problématique initiale, les expériences réalisées dans trois cadres différents conduisent donc à privilégier une stratégie reposant sur une bonne adaptation à la géométrie de la cible, complétée par une persistance intermédiaire du momentum.

Cette conclusion ne constitue pas une optimalité universelle. Elle représente un résultat empirique robuste sur les domaines expérimentaux étudiés et fournit une base pour poursuivre l'étude de méthodes MCMC adaptées aux modèles géostatistiques de grande dimension.

Annexe A

Validations numériques complémentaires

Cette annexe rassemble les principaux contrôles numériques réalisés au cours du développement des méthodes d'échantillonnage étudiées dans ce mémoire.

L'objectif n'est pas de reproduire les analyses présentées dans les chapitres précédents, mais de vérifier certaines étapes essentielles de l'implémentation : résolutions matricielles dans le modèle gaussien, calcul des gradients dans les modèles non gaussiens et convergence des procédures utilisées pour déterminer le MAP.

A.1 Validations dans le modèle gaussien

Le modèle gaussien présente l'avantage de disposer d'une distribution *a posteriori* analytique du champ latent. Cette propriété permet de contrôler directement plusieurs opérations matricielles intervenant dans l'algorithme.

La moyenne *a posteriori* calculée à partir de la factorisation de Cholesky a tout d'abord été comparée à celle obtenue par résolution directe du système linéaire.

Les opérations associées aux préconditionnements ont également été vérifiées en comparant le calcul de

$$C^{-1}v$$

obtenu par résolutions triangulaires à une résolution directe.
Enfin, la génération du momentum

$$p \sim \mathcal{N}(0, C)$$

a été contrôlée empiriquement à partir de 10 000 simulations.
Les principaux résultats sont regroupés dans le Tableau A.1.

TABLE A.1 – Principales validations numériques dans le modèle gaussien.

Vérification	Erreur observée
Moyenne analytique – comparaison avec résolution directe	1.93×10^{-14}
Résidu du système pour la moyenne analytique	3.68×10^{-14}
Calcul de $C^{-1}v$ – préconditionnement <i>a priori</i>	3.46×10^{-14}
Calcul de $C^{-1}v$ – préconditionnement <i>a posteriori</i>	3.69×10^{-14}
Covariance du momentum – erreur relative maximale	3.09 %

Les erreurs associées aux résolutions linéaires sont de l'ordre de la précision numérique machine.

L'écart observé lors de la vérification empirique de la covariance du momentum est plus élevé, car il repose sur un nombre fini de simulations. Une erreur relative maximale d'environ 3 % reste compatible avec la variabilité Monte-Carlo attendue.

Ces résultats confirment la cohérence des principales opérations matricielles utilisées dans l'implémentation.

A.2 Validations dans le modèle binaire

Dans le modèle binaire, la distribution *a posteriori* du champ latent ne possède plus de forme analytique explicite.

Les contrôles portent donc principalement sur deux éléments essentiels : le gradient de la log-postérieure utilisé par MALA et la convergence de la méthode de Newton utilisée pour déterminer le MAP.

A.2.1 Validation numérique du gradient

Le gradient analytique a été comparé à une approximation par différences finies centrées.

Pour une composante w_j ,

$$\frac{\partial \log \pi(w \mid y)}{\partial w_j} \simeq \frac{\log \pi(w + \varepsilon e_j \mid y) - \log \pi(w - \varepsilon e_j \mid y)}{2\varepsilon}, \quad (\text{A.1})$$

avec

$$\varepsilon = 10^{-6}.$$

La comparaison est réalisée pour plusieurs composantes réparties dans le champ latent.

TABLE A.2 – Validation numérique du gradient dans le modèle binaire.

Indice	Gradient analytique	Gradient numérique	Écart absolu
1	0.2643059	0.2643060	7.95×10^{-8}
10	0.2695285	0.2695283	1.55×10^{-7}
100	0.2732081	0.2732081	1.41×10^{-8}
1000	0.2720559	0.2720558	8.37×10^{-8}
5000	-0.7279488	-0.7279486	2.03×10^{-7}
10000	0.2671177	0.2671177	3.72×10^{-8}

Les écarts restent inférieurs à environ

$$2.1 \times 10^{-7},$$

ce qui confirme l'accord entre le gradient analytique et son approximation numérique.

A.2.2 Convergence du calcul du MAP

Le MAP du champ latent est obtenu par une méthode de Newton utilisant la courbure locale de la log-postérieure.

Sur la configuration utilisée pour la validation numérique, la procédure converge en six itérations.

TABLE A.3 – Convergence de la méthode de Newton utilisée pour le calcul du MAP dans le modèle binaire.

Itération	$\max w^{(k+1)} - w^{(k)} $	$\max \nabla \log \pi(w^{(k)} y) $
1	1.29	7.37×10^{-1}
2	5.73×10^{-1}	6.49×10^{-2}
3	1.56×10^{-1}	1.11×10^{-2}
4	8.92×10^{-3}	6.57×10^{-4}
5	2.38×10^{-5}	2.00×10^{-6}
6	1.52×10^{-10}	1.95×10^{-11}

La diminution simultanée du déplacement entre deux itérations et de la norme du gradient confirme la convergence numérique de la procédure.

Le MAP ainsi obtenu est ensuite utilisé comme point initial de la chaîne et pour construire la matrice de courbure

$$Q_{\text{MAP}} = Q_0 + D_{\text{MAP}},$$

employée dans le préconditionnement au MAP.

A.3 Validations dans le modèle de Poisson

Comme dans le modèle binaire, aucune expression analytique de la distribution *a posteriori* complète du champ latent n'est disponible dans le modèle de Poisson.

Les contrôles numériques portent donc sur le gradient, la convergence du calcul du MAP et le comportement des deux préconditionnements sur une configuration de référence.

A.3.1 Validation numérique du gradient

Avant son utilisation dans le calcul du MAP et dans MALA, le gradient analytique de la log-postérieure est comparé à une approximation par différences finies centrées.

Pour une composante w_j ,

$$\frac{\partial \log \pi(w | y)}{\partial w_j} \simeq \frac{\log \pi(w + \varepsilon e_j | y) - \log \pi(w - \varepsilon e_j | y)}{2\varepsilon}, \quad (\text{A.2})$$

avec

$$\varepsilon = 10^{-6}.$$

TABLE A.4 – Comparaison entre gradient analytique et gradient numérique dans le modèle de Poisson.

Indice	Gradient analytique	Gradient numérique	Erreur absolue
1	-0.3642343	-0.3642343	4.27×10^{-8}
10	-0.3662388	-0.3662389	1.19×10^{-8}
100	0.6330203	0.6330202	8.42×10^{-8}
500	-0.3672798	-0.3672798	4.49×10^{-8}
1000	1.6338107	1.6338107	1.55×10^{-8}

Les écarts sont de l'ordre de

$$10^{-8},$$

ce qui confirme numériquement l'expression analytique du gradient utilisée dans MALA.

A.3.2 Convergence du calcul du MAP

Le MAP est obtenu par une méthode de Newton avec réduction du pas lorsque la mise à jour proposée n'augmente pas la log-postérieure.

Sur la configuration utilisée pour la validation, la procédure converge en six itérations.

À la convergence, le maximum de la valeur absolue des composantes du gradient est égal à

$$2.41 \times 10^{-12},$$

et sa norme euclidienne vaut

$$9.48 \times 10^{-12}.$$

Ces valeurs très proches de zéro montrent que la solution obtenue satisfait numériquement la condition de stationnarité du MAP.

Pour cette même configuration, la corrélation entre le champ latent simulé et le MAP est

$$0.963,$$

et la RMSE de reconstruction correspondante vaut

$$0.251.$$

Ces deux dernières valeurs ne constituent pas un critère de convergence de la méthode de Newton. Elles fournissent simplement une indication complémentaire sur la proximité entre le mode postérieur et le champ latent ayant généré les données.

A.3.3 Comparaison sur une configuration de référence

Avant l'exécution du plan factoriel complet, les préconditionnements *a priori* et au MAP sont comparés sur une configuration de référence.

TABLE A.5 – Comparaison des deux préconditionnements sur une configuration de référence du modèle de Poisson.

Préconditionnement	Accept.	Pas final	ESS méd.	ESS min.	RMSE champ
A priori	0.590	0.097	81.00	37.34	0.244
Au MAP	0.490	0.559	445.09	358.40	0.248

Les RMSE de reconstruction sont très proches :

$$0.244 \quad \text{et} \quad 0.248.$$

En revanche, les diagnostics d'autocorrélation diffèrent fortement. L'ESS médian passe de

$$81.00$$

avec le préconditionnement *a priori* à

$$445.09$$

avec le préconditionnement au MAP.

L'ESS minimal augmente parallèlement de

$$37.34$$

à

Le préconditionnement au MAP permet également d'utiliser un pas final nettement plus élevé.

Cette comparaison préliminaire ne constitue pas à elle seule une analyse de performance générale, puisqu'elle repose sur une seule configuration. Elle a principalement servi à vérifier le comportement attendu de l'implémentation avant l'exécution des 1620 chaînes du plan factoriel présenté au chapitre 7.

Bilan des validations

Les contrôles numériques présentés dans cette annexe permettent de vérifier plusieurs éléments essentiels de l'implémentation.

Dans le modèle gaussien, les résolutions reposant sur les factorisations de Cholesky coïncident avec les calculs directs à la précision numérique près. La simulation du momentum fournit également une covariance empirique compatible avec celle attendue.

Dans les modèles binaire et de Poisson, les gradients analytiques sont en accord avec les approximations obtenues par différences finies. Les procédures de Newton utilisées pour calculer le MAP convergent vers des points pour lesquels le gradient de la log-postérieure est numériquement proche de zéro.

Ces validations apportent ainsi des contrôles complémentaires aux résultats présentés dans les chapitres principaux et renforcent la vérification de l'implémentation utilisée dans les expériences numériques.

Bibliographie

- [Coube-Sisqueille, 2021] Coube-Sisqueille, S. (2021). *MCMC Algorithms and Hierarchical Architectures for Spatial Modeling Using Nearest Neighbor Gaussian Processes*. PhD thesis, Université de Pau et des Pays de l'Adour. NNT : 2021PAUU3020 ; HAL : tel-03462636.
- [Girolami and Calderhead, 2011] Girolami, M. and Calderhead, B. (2011). Riemann manifold langevin and hamiltonian monte carlo methods. *Journal of the Royal Statistical Society : Series B (Statistical Methodology)*, 73(2) :123–214.
- [Neal, 2011] Neal, R. M. (2011). Mcmc using hamiltonian dynamics. In Brooks, S., Gelman, A., Jones, G. L., and Meng, X.-L., editors, *Handbook of Markov Chain Monte Carlo*, chapter 5. Chapman & Hall/CRC.
- [Robbins and Monro, 1951] Robbins, H. and Monro, S. (1951). A stochastic approximation method. *The Annals of Mathematical Statistics*, 22(3) :400–407.
- [Roberts and Rosenthal, 1998] Roberts, G. O. and Rosenthal, J. S. (1998). Optimal scaling of discrete approximations to langevin diffusions. *Journal of the Royal Statistical Society : Series B (Statistical Methodology)*, 60(1) :255–268.
- [Rue and Held, 2005] Rue, H. and Held, L. (2005). *Gaussian Markov Random Fields : Theory and Applications*. Monographs on Statistics and Applied Probability. Chapman and Hall/CRC.